

SMEM: A Mixture-of-Experts Routing Global-Local Framework for Spatial Multi-Omics Domain Identification

Haobin Xu

摘要—空间多组学技术能够同时测量空间数据及多层分子信息，为解析细胞组织与组织异质性提供了新的方式，在生理病理领域至关重要。近年来，基于空间多组学的聚类分析取得了显著进展，但现有方法存在诸多不足，大多数一阶图不足以表示复杂组织拓扑，并且会丢失长程上下文；现有方法主要依赖固定融合策略，仅限于简单模态加权，无法有效整合各组学的信息；同时，深聚类在不平衡空间域下容易出现 cluster collapse。为此，我们提出 SMEM，一种基于 MoE 路由的空间多组学框架。首先，我们引入 motif 高阶图，丰富局部细胞拓扑；其次，模型通过图编码器与基于 Transformer 的空间表征，同时捕获局部和全局特征；最后，模型在信息融合阶段引入 MoE 模块，通过动态门控，实现 dynamic expert routing，将每个 spot 路由到专门化专家；我们还设计了 DEC 稳定性感知的聚类优化策略，以缓解死簇塌陷并提升训练鲁棒性。大量实验表明，SMEM 的聚类性能优于目前所有的最先进方法，并产生了更具连贯性和生物可解释性的空间域，为鲁棒的空间多组学解码与下游生物分析提供了有效方案。

Index Terms—spatial multi-omics、domain identification、motif graph、mixture of experts、deep clustering

I. INTRODUCTION

细胞的空间组织是组织功能的基本决定因素，也是理解并研究生理病理机制的关键。单细胞 RNA 测序 (scRNA-seq) 等单组学测量技术已经发展成熟，并改变了我们对细胞类型发现与理解的方式，但其基于解离的检测破坏了原生组织上下文，致使无法有效解析组学间的空间信息；而空间转录组学，保留了组织原位信息，但通常仍局限于单一分子层面的测量，难以同时捕获表观遗传、蛋白质和代谢等多层级调控信息，也难以完整表征细胞状态转换、细胞间通讯及微环境依赖的分子机制。此外，不同空间转录组平台在空间分辨率、检测通量、分子覆盖度和样本兼容性之间仍需权衡，单独依赖

转录层信息也难以反映转录后调控和蛋白质功能状态。[?]

近年来，基于空间的多组学方法开始兴起，在 2022 年被《自然》杂志列为七大关键技术之一，测量对象已从单一分子层扩展到同一细胞或同一组织切片上的多模态共测量，使研究者能够同时观察细胞内分子状态与细胞间空间组织规律。与单组学技术不同，空间多组学展现组织结构、细胞状态、分子层级与微环境依赖调控之间的关联，通过对单细胞基因组、转录组、蛋白质组等及空间信息的联合分析，解析细胞相互作用、空间邻域和疾病相关分子回路。目前主流的空间多组学技术大体可分为三类，第一类是测序/空间条形码型，包括基于阵列、珠子或微流控条形码的路线，代表平台有 Visium、Slide-seq、Stereo-seq、DBiT-seq，以及在其基础上扩展出的 SPOTS、SM-Omics、Stereo-CITE-seq、MISAR-seq 等；第二类是原位成像型，包括基于 ISS 或多重 FISH 的平台，如 Xenium、MERFISH/MERSCOPE、seqFISH、CosMx 等；第三类则是成像质谱型。

不同类别的空间多组学技术能够为多组学分析提供全面的生物信息与空间信息。该技术整合的计算目标为，在保留组织几何结构与局部邻域关系的前提下，学习 biologically meaningful latent space，并以此支持 spatial domain identification / clustering、marker discovery、cell-cell communication、pathway/GO 分析、微环境分层、疾病区域比较和调控网络推断等。可以看出，空间域划分是多数下游分析的前置步骤，空间聚类是测序分析的关键步骤，其核心目标是识别基因表达与组织结构具有空间关联性的区域，从而为每个捕获的细胞点或细胞精准分配空间域标签。因此，如何正确精准地进行空间多组学整合，并进行聚类下游任务分

析，就成为了目前的核心任务。

与之对应，面向组学整合的计算方法也持续发展，大致可以分为四种类别：单组学单细胞表征学习、非空间多组学整合、空间单组学整合，以及空间多组学整合。总体而言，图模型，尤其是利用邻接关系和局部拓扑的图神经网络，在空间相关任务中已经成为最常见的建模范式之一；而在非空间多组学整合中，则与深度生成模型、矩阵分解和概率建模等数学方法与机器学习方法共同构成主流技术路线。在早期的单组学单细胞分析中，许多方法已经开始借助图神经网络刻画细胞间关系。例如，scGNN 将细胞-细胞关系表示为图结构，并结合自编码器学习，用于聚类与插补；scGCN 利用图卷积网络实现跨组织、跨平台的数据知识迁移；scGAC 则通过图注意力自编码器学习特征表示。这些方法，为后续研究，奠定了以图建模细胞关系的技术基础，但缺点清晰。它们主要围绕组学本身信息，构建细胞图，并未显式建模组织空间结构，也并不支持多组学的整合分析，而更多是对单组学信息进行结构化表征、降噪和特征提取。

为了使用不同信息进行联合分析，研究重心进一步转向非空间多组学整合，使用联合潜空间学习、显式跨组学约束和异质特征空间对齐等方法。*** 等人提出了 totalVI，对 CITE-seq 的 RNA 与蛋白数据进行联合概率建模；基于此，*** 等人进一步提出了 MultiVI，将方法推广到 RNA-ATAC 或 multimodal/single-modality 混等合数据中，使缺失模态的细胞也能被纳入统一表示。在非空间多组学整合中，GLUE 是最具代表性的框架之一，引入了 knowledge-based guidance graph，显式建模不同组学层之间的 regulatory interactions。尽管这些方法拥有跨组学对齐能力，但它们的建模对象仍是非空间细胞集合，不能充分解决 spatial domain identification。

为弥补这一缺口，一些研究 [cite] 开始系统引入空间坐标、组织形态和跨切片关系。与非空间组学整合不同的是，这类方法要求，不仅要保持组织边界的连续性，还要依据空间信息分析，恢复出真实组织结构，代表方法有 SpaGCN、STAGATE、GraphST、STALinger 等。这些方法提升了空间建模能力，但也存在明显的局限性，它们依赖单一组学，难以利用多组学信息（RNA + ADT 或 RNA + ATAC）的互补性。

随着同一组织切片上 transcriptome - proteome、transcriptome - epigenome 乃至三模态空间共测技术

的发展，如何在保留空间组织结构的同时整合异质组学信号，已成为空间多组学分析中的核心问题。因此，空间多组学整合方法开始被探索，并取得了显著进展。*** 等人提出的 SpatialGlue 是早期代表性工作之一，它为每个模态分别构建 spatial graph 与 feature graph，并使用双层 attention 机制，先在模态内融合信息，再在模态间聚合不同组学表征。该网络展示了空间多组学整合相较于特征拼接，或非空间多组学整合的优势，推动了 spatially informed cross-omics integration 的发展。SpatialGlue 的局限在于，其仍然依赖一阶邻域结构，更偏局部图语义，长程全局上下文与高阶拓扑表达能力有限。后续的 SpaFusion、SpaMICS 等方法，均基于 SpatialGlue 进行了改进，其本质仍然是使用 graph 表示拓扑，并通过各种操作进行模态融合，进而实现空间多组学整合。

在此基础上，后续研究针对不同的应用场景进行了扩展。SWITCH 将问题扩展到 unpaired spatial multi-omics integration，通过 cycle-mapping 生成 pseudo-pairs；SpatialEx/SpatialEx+ 则进一步面向 serial-section / diagonal integration，利用 histology 作为 universal anchor 跨切片整合多组学；而最新的 SpatialCOC 强调从 spatial prior 中学习 omics-specific spatial distributions，并显式刻画模态间 nonlinear correlations。

然而，现有方法仍存在若干尚未充分解决的问题。第一，现有方法的跨模态融合，通常依赖 feature concatenation、shared latent factors、attention-weighted aggregation 或连续空间校正，也缺乏面向不同 spot 的 node-wise routing 或 expert specialization 机制。因此，在组织异质性较强、不同模态贡献随空间位置显著变化的场景中，现有融合策略难以充分刻画模态间的互补性与差异性；

第二，许多图模型仍以固定局部邻域或 pairwise neighborhood aggregation 作为主要空间先验，其表达能力受限于一阶或低阶拓扑关系，难以同时捕捉细粒度局部结构、高阶空间依赖与长程组织上下文。虽然已有方法开始引入多邻域、hypergraph 或 histology-derived global context，但高阶拓扑与跨组学动态融合无法很好耦合。

第三，深度空间多组学整合通常还伴随训练层面的不稳定性。不同组学模态在维度、噪声水平、稀疏性和生物信息量上存在显著差异，容易造成强模态主导、

弱模态被抑制以及小簇结构塌陷。已有 shared/private disentanglement 或 imbalance-aware optimization 能在一定程度上缓解信息混合不清和训练贡献失衡的问题,但尚未充分实现面向每个节点的动态专家选择与稳定聚类协同优化。因此,一个更理想的空间多组学整合框架,应同时具备高阶空间结构建模能力、spot-specific 跨模态贡献估计能力以及 node-wise expert routing 能力,从而在模态贡献局部变化显著、组织结构高度异质的场景下,实现更稳健、更可解释的空间组织解析。

为了实现上述目标,本文提出 SMEM,一种基于混合专家(MoE)动态路由的多模态融合与稳定深度聚类框架。我们的方法在三个重要方面不同于现有方法。具体来说,针对第一个问题,不同于大多数先前方法采用的固定融合方案,我们在信息融合阶段,借鉴了大语言模型(LLM)领域的混合专家架构,并且构建了四个专家模块,进行模态感知。在该框架下,网络进行逐节点自适应的跨组学融合,不同的 spot 根据其共识与差异模式,分别由不同专家机制整合。同时,为了增强模型表达力与稳定性,我们优化了 MoE 的输出。针对第二个问题,为了解决一阶邻域图的不足,SMEM 使用了 motif 增强图,丰富了组学内拓扑建模,并将其与基于 Transformer 的全局上下文建模相结合。第三,在表征融合之外,我们显式引入稳定性感知的聚类优化,以减少死簇塌陷并提升训练鲁棒性。这些设计选择使我们的框架特别适合异质和不平衡的空间多组学数据。

总的来说,本研究的贡献有:

- 我们提出了 SMEM,一种高效空间多组学整合信息框架,创新性地 将 MoE 动态路由机制引入到空间多组学整合中,实现精准的跨模态信息融合。
- 我们设计了一个局部—全局编码器,通过构建高阶图,接收不同的组学信息,将共享权重的双图 GCN 与 Transformer 分支相结合,并通过自适应残差注意力机制进行融合。
- 我们开发了一种稳定性感知的深度聚类策略,以缓解簇塌陷问题,并提升模型在空间域不平衡条件下的鲁棒性。
- 为验证方法的有效性,我们在多个数据集上对方法进行了测试。实验结果表明,SMEM 的性能显著优于所有最先进方法,并表现出更强的鲁棒性和生物分析价值。

II. RELATED WORKS

A. Graph-based spatial omics and spatial multi-omics integration

基于图的建模方法,已成为空间组学分析中的主流方法。图能够自然编码组织拓扑结构,将空间点或细胞根据空间邻接关系、分子相似性、组织学背景或它们的组合进行连接。因此,早期的空间转录组方法均使用了图进行建模,如 SpaGCN、STAGATE、SEDR 和 GraphST。结果表明,图卷积、图注意力以及图自编码方法能够有效传播局部组织信息,提高空间域识别能力。尽管这些方法针对单组学开发,但它们确立了图学习作为建模方法的先河。

在此基础上,大多数空间多组学整合方法,同样依赖图来建立空间拓扑。经典方法 SpatialGlue 通过图神经网络整合空间与多组学,并在此基础上通过双重注意力机制实现跨组学聚合;COSMOS 使用图卷积通道对配对模态进行编码,并通过对比学习将其整合为统一表示;SpaMI 和 soFusion 同样采用基于图的编码器,学习各组学特征,随后执行跨模态融合,SMART 则通过度量学习进一步优化图聚合。近期,SpaMosaic 同样利用图神经网络构建统一的潜在表示空间。总体而言,这些研究表明,图构建已成为空间多组学整合的主要策略之一。

一些最新研究进一步指出 [], 在图学习中,仅依赖成对关系,或一阶图,不足以刻画复杂的关系拓扑 []。因此出现了高阶图或者超图。在其中,代表方法 SpaFusion,将一阶邻接关系与高阶结构相结合,构建统一的高阶图,用于空间组学聚类;此外,基于超图(如 HAST 和 HyperSTAR)的方法,从不同的视角中聚合超边,来建模高阶关系;而 GraphTucker 则从张量角度探索了多维高阶结构。

然而,仅仅依赖于图或高阶图的方法,无法有效处理空间域内模态之间的复杂关系。跨组学融合通常通过拼接、注意力加权、子空间分解或其他全局共享的聚合函数实现,然而在复杂组织中,这一假设往往过于理想化,因为不同解剖区域、疾病微环境以及过渡边界中的模态可靠性和跨组学互补性可能存在显著差异。

B. Modality imbalance and stability in spatial domain discovery

尽管空间多组学整合技术发展迅速,但是多模态融合带来了一个挑战:不同组学层往往具有显著不同的特




图 1. SMEM 的总体架构图。Method D 稳定性展示之聚类优化部分，并未在网络架构图中显著提及。

征维度、信噪比、稀疏程度以及生物学信息量，若所有模态在同一优化目标下联合训练，会导致 latent space 不够精准。近期诸多空间多组学研究已逐渐关注该问题。SMART 指出，空间坐标的引入进一步增加了统一表征学习难度，为了缓解该问题，SpaBalance 使用了梯度协调和自适应特征分解，实现组学间贡献的动态平衡。

另一个相关挑战在于空间域本身的稳定性。空间区域划分多为无监督任务，易受测序噪声、图构建方式、以及复杂组织形态的干扰。为提升模型鲁棒性，现有主流方法普遍采用共识聚类的策略。例如，SpatialCVGAE 通过融合多组隐表征与共识聚类，缓解数据噪声带来的不稳定性；EnSDD 对多个基础区域检测模型进行动态加权；Space 则通过一致性感知的共识学习，调和不同算法的输出差异。

然而，现有方法大多将模态平衡与聚类稳定性视为两个问题。前者主要关注全局层面的跨组学优化，后者则更多依赖后验的共识或集成聚合，并未在表征学习阶段，对聚类分配坍塌问题施加约束。因此，如何在模态不均衡条件下，同时学习稳定的空间域表示，这一联合问题仍缺乏充分研究。

C. Mixture-of-experts for adaptive cross-modal fusion

混合专家模型 (mixture-of-experts, MoE) 为自适应信息融合提供了一种新的机制：它通过一组专家网络

与一个可学习的门控函数相结合，使得模型能够动态选择不同的专家组合。在机器学习领域，诸如 MMoE 的变体已经被广泛应用，成为了多模态模型 (MLLM) 的关键技术。近年来，scMM、FuseMoE 和 Spatial Mixture-of-Experts 等工作进一步表明，当空间结构存在差异时，专家动态分配机制能够有效提升模型性能。因此，研究表明 [?], MoE 技术同样能被用于组学分析任务。

与之相对，当前绝大多数空间多组学整合方法仍依赖静态、架构固定的融合机制。现有融合方式主要分为三类：拼接融合、注意力引导融合与空间分解融合。代表性方法包括 SpatialGlue、SpaMI、SpaMICS、MultiGATE、SWITCH 等，通过双向注意力、对比学习、子空间拆解等不同方法，但总体上仍依赖共享或固定的融合函数，而非基于空间位置的专家路由。在复杂组织中，跨组学互补性、生物学相关性往往会随着解剖区域变化，因此静态融合可能受到限制。由此，将 MoE 引入空间多组学整合，实现自适应的跨模态融合，是一种有效的策略。

III. METHODS

在本章，我们将详细介绍 SMEM 的架构。SMEM 主要包含四个组件 (见图 1)，分别是输入与图构建、局部 - 全局组学内编码、modality-aware mixture-of-experts, MA-MoE 跨模态路由和聚类稳定模块。

总体网络来看, SMEM 通过以逐节点混合专家路由替代全局共享的跨组学融合策略, 并增强 DEC 聚类算法对小众域的抗坍塌能力, 有效提升空间多组学的域识别效果。接下来, 将对各个模块进行详细介绍。

A. 输入与图构建

为了对输入的生物信息数据与空间信息进行更好地分析, 我们构建了图以捕捉细胞间的关联与空间域的关系。

为了适配双组学数据集, 以及空间数据, 针对两个在同一组织切片中配对测量的数据, 给定组学矩阵 $\mathbf{X}^{(1)}$ 和 $\mathbf{X}^{(2)}$, 以及共享空间坐标 $\mathbf{L}$ 。SMEM 的目标是习得 integrated representation $\mathbf{Z}$, 并基于软聚类分配 $q_{ik}^{(0)}$ 推断每个 spot 的空间域标签, 其映射关系如下:

$$\mathbf{Z} = f_{\Theta}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)}\mathbf{L}) \in \mathbb{R}^{N \times d},$$

$$\hat{y}_i = \arg \max_{k \in \{1, \dots, K\}} q_{ik}^{(0)} \quad (1)$$

其中, $\mathbf{X}^{(1)}$ 和 $\mathbf{X}^{(2)}$ 分别表示两个组学层的预处理特征矩阵, $f_{\Theta}(\cdot)$ 为 SMEM 学习的非线性映射函数, Θ 表示模型中所有可训练参数的集合。

在对输入的组学信息进行初步处理后, SMEM 对每个组学进行构建一阶图, 其中分为两类: 由空间坐标得到的 spatial graph, 以及由 PCA 后分子特征得到的 feature graph, 二者均采用 KNN 构建, 图 $A_{(v)}$ 如下:

$$A_{\bullet, ij}^{(v)} = \mathbb{I}\left(j \in \mathcal{N}_{K_{\bullet}}(\mathbf{u}_i^{(v, \bullet)})\right),$$

$$\bullet \in \{s, f\}, v \in \{1, 2\} \quad (2)$$

其中, 邻接矩阵包含 $A_{spatial}$ 与 $A_{feature}$, 因此 $\bullet \in \{s, f\}$ 表示图的类型。 $\mathcal{N}_{K_{\bullet}}(\cdot)$ 表示对应空间中的 $K_{\bullet}$ -nearest neighbors, $\mathbb{I}(\cdot)$ 为指示函数。

虽然一维邻接矩阵已经表述了组学直接的关联信息, 但是面对更复杂的组织形态, 需要信息的高阶呈现。一阶图主要描述成对节点之间的连接关系, 难以充分反映细胞群体内部更高阶的组织模式。因此, SMEM 引入了三节点高阶图, 以此弥补这一不足应对并构建更加复杂、更加变化的组织形态。模体 $\square$ 作为图中高频出现的子图结构, 其蕴含着细胞群体空间组织的重要信息, 其中, 三节点模体是典型的高阶结构, 能够捕捉复杂细胞间的相互作用。高阶图的构建过程, 收到 Wang 等人的工作 [?] 启发, 使用共现矩阵 $\mathbf{C}^{(v)} \in \mathbb{R}^{N \times N}$, 用于量化 spots 在高阶局部结构中的共现关系。随后, 使用

一阶 feature graph 与 motif 图, 整合为统一的 motif-enhanced high-order graph。公式如下:

$$\mathbf{A}_h^{(v)} = \rho_f \bar{\mathbf{A}}_f^{(v)} + \rho_c \bar{\mathbf{C}}^{(v)} \quad (3)$$

其中, $\bar{\mathbf{A}}_f^{(v)}$ 表示归一化后的第 v 个特征图, $\bar{\mathbf{C}}^{(v)}$ 表示归一化后的 three-node motif 共现矩阵。 ρ_f 和 ρ_c 是可学习的系数, 分别控制一阶信息和高阶结构信息的贡献。

同时, 空间坐标信息对于生物信息的整合与对其同样重要。为了有效利用空间信息, SMEM 构建了空间邻接矩阵, 使用欧氏距离计算近邻细胞, 并使用归一化后的空间图 $\bar{\mathbf{A}}_s^{(v)}$ 与 $\bar{\mathbf{A}}_f^{(v)}$ 得到 refined spatial graph。 refined spatial graph 的表示如下:

$$\mathbf{A}_r^{(v)} = \bar{\mathbf{A}}_s^{(v)} \odot \bar{\mathbf{A}}_f^{(v)} \quad (4)$$

使用 Hadamard product 得到, 以此保留同时满足空间邻近和分子相似的边。

B. 局部 - 全局组学内编码

为了更加精准地进行对齐与整合, SMEM 需要同时捕获来自细胞局部特征与全局分布规律的信息。图自编码器 (Graph AutoEncoder, GAE) 是一种基于图的自编码器, 用于学习图的表示。SMEM 中, 图自编码器被用于对组学特征进行编码, 进行局部建模, 以获得图的低维表示。

1. 局部编码

第一个图自编码器以 $(\mathbf{X}^{(v)}, \mathbf{A}_s^{(v)})$ 为输入, 用于学习空间邻域驱动的局部表示; 第二个图自编码器以 $(\mathbf{X}^{(v)}, \mathbf{A}_h^{(v)})$ 为输入, 用于学习高阶 motif 约束的局部表示。图卷积编码器的第 l 层传播过程可写为:

$$\mathbf{H}_g^{(v, l+1)} = \sigma\left(\tilde{\mathbf{A}}_g^{(v)} \mathbf{H}_g^{(v, l)} \mathbf{W}_g^{(v, l)}\right), g \in \{s, h\} \quad (5)$$

可以看出, $\tilde{\mathbf{A}}_g^{(v)}$ 表示归一化后的邻接矩阵, $\mathbf{H}_g^{(v, 0)} = \mathbf{X}^{(v)}$, $\mathbf{W}$ 为可学习参数。经过多层图卷积后, 两个局部分支分别输出:

$$\mathbf{Z}_s^{(v)} = \text{GCN}_s^{(v)}\left(\mathbf{X}^{(v)}, \tilde{\mathbf{A}}_s^{(v)}\right) \quad (6)$$

与

$$\mathbf{Z}_h^{(v)} = \text{GCN}_h^{(v)}\left(\mathbf{X}^{(v)}, \tilde{\mathbf{A}}_h^{(v)}\right) \quad (7)$$

GAE encoder 重构对应的图结构为

$$\hat{\mathbf{A}}_g^{(v)} = \sigma\left(\mathbf{Z}_g^{(v)} \mathbf{Z}_g^{(v)\top}\right), g \in \{s, h\} \quad (8)$$

其中 $\hat{\mathbf{A}}_s^{(v)}$ 和 $\hat{\mathbf{A}}_h^{(v)}$ 分别表示空间图和高阶特征图的重构结果。对应的图结构重构损失定义为：

$$\mathcal{L}_{\text{graph}}^{(v)} = \omega_s \left\| \hat{\mathbf{A}}_s^{(v)} - \mathbf{A}_s^{(v)} \right\|_F^2 + \omega_h \left\| \hat{\mathbf{A}}_h^{(v)} - \mathbf{A}_h^{(v)} \right\|_F^2 \quad (9)$$

其中 ω_s 和 ω_h 控制两个局部图重构目标的贡献。

2. 全局编码

虽然图自编码器能够有效捕捉局部空间结构和特征相似性，但局部图传播通常受限于邻域范围，无法理解全局建模信息与分布规律。为此，SMEM 引入 Transformer 编码器，从组学特征矩阵中学习全局上下文依赖。对于第 v 个组学，Transformer 全局分支定义为：

$$\mathbf{Z}_t^{(v)} = \text{TransformerEnc}^{(v)}(\mathbf{X}^{(v)}) \quad (10)$$

其中 $\mathbf{Z}_t^{(v)} \in \mathbb{R}^{N \times d}$ 表示全局上下文表征。以此，全局分支使用自注意力机制，建模任意两个 spot 之间的潜在依赖关系，通过该分支，补充局部图分支难以捕捉的长程组织结构信息。同时，解码器重构输入特征，表示如下：

$$\hat{\mathbf{X}}_t^{(v)} = \text{TransformerDec}^{(v)}(\tilde{\mathbf{Z}}^{(v)}) \quad (11)$$

对应的全局特征重构损失定义为

$$\mathcal{L}_{\text{feat}}^{(v)} = \omega_x \left\| \hat{\mathbf{X}}_t^{(v)} - \mathbf{X}^{(v)} \right\|_F^2 \quad (12)$$

其中 ω_x 控制特征重构项的权重。

总体来说，三个分支的输出为 $\mathbf{Z}_r^{(v)}$, $\mathbf{Z}_h^{(v)}$ 和 $\mathbf{Z}_t^{(v)}$ 。三类表示通过 softmax-normalized branch weights 进行组学内融合，并通过 global embedding attention 进一步扩大 receptive field，如式13：

$$\mathbf{U}^{(v)} = \sum_{b \in \{r, h, t\}} \alpha_b^{(v)} \odot \mathbf{Z}_b^{(v)}, \quad (13)$$

$$[\alpha_r^{(v)}, \alpha_h^{(v)}, \alpha_t^{(v)}] = \text{softmax}_b([\Omega_r^{(v)}, \Omega_h^{(v)}, \Omega_t^{(v)}])$$

在使用全局分支和局部分枝得到输出后，SMEM 将三个输出进行融合与残差连接（如图??），最终的输出为

$$\tilde{\mathbf{Z}}^{(v)} = \mathbf{Z}_\ell^{(v)} + \gamma^{(v)} \mathbf{R}^{(v)} \mathbf{Z}_\ell^{(v)} \quad (14)$$

其中的 $\gamma^{(v)}$ 为可学习残差系数，送入下面的 Modality-aware MoE 模块中。

C. Modality-aware MoE 模块

传统跨组学融合通常使用拼接、加权平均或全局共享的 fusion MLP。这类方法有明显缺陷。它们认为，所

有 spot 都应使用同一个跨组学交互模式。然而在真实组织中，不同空间区域的组学可靠性和互补性可能不同，转录组特征更易识别转录活性区域，而蛋白质组、表观基因组信号可清晰区分免疫区、基质区与组织边界区。同时，模态差异并不均匀，小型空间区域、的组学一致性，与大范围均质区域存在明显区别。

因此，SMEM 提出 MA-MoE 模块，该模块不学习单一融合函数，而是为每个位点动态分配专家的组合权重。同时，不同专家负责建模不同的组学交互，路由网络根据嵌入特征，自适应调控各专家的贡献占比。

1. 路由与门控

在该阶段，跨组学融合不应只依赖两个 embedding 的简单拼接，还应显式建模它们在哪些维度相互支持、在哪些维度存在冲突。MA-MoE 模块的输入如下：

$$\mathbf{r}_i = \left[\tilde{\mathbf{z}}_i^{(1)} \parallel \tilde{\mathbf{z}}_i^{(2)} \parallel \tilde{\mathbf{z}}_i^{(1)} \odot \tilde{\mathbf{z}}_i^{(2)} \parallel \left| \tilde{\mathbf{z}}_i^{(1)} - \tilde{\mathbf{z}}_i^{(2)} \right| \right] \quad (15)$$

$\tilde{\mathbf{z}}_i$ 表示第 i 个 spot 在两个组学中的表示， $\parallel$ 表示向量拼接。我们设计为四种信息输入，分别代表两个组学各自的表示、跨组学一致性、以及跨组学差异。通过此输入特征，SMEM 将跨组学整合建模为 spot-wise routing problem。

随后，输入被送入 noisy softmax 专家路由，用以增强训练早期的专家探索，避免所有 spots 过早集中到某一个专家，造成 expert collapse。该路由是 spot-specific 的，每个 spot 都可以拥有不同的专家组合，使 SMEM 能够动态选择融合机制。专家路由被表示为

$$\mathbf{g}_i = \text{softmax}(\phi_g(\mathbf{r}_i) + \boldsymbol{\epsilon}_i), \boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \lambda_n^2 \text{diag}(\boldsymbol{\sigma}_i^2)) \quad (16)$$

其中， $\phi_g(\cdot)$ 表示 routing network，将输入 $\mathbf{r}_i$ 映射为不同专家的未归一化选择分数； g_{ie} 表示第 i 个 spot 选择第 e 个专家的概率。

2. 专家函数

路由后的特征进入至关重要的专家，它们是 FeatureGatingExpert、HardwardExpert、VarianceExpert 和 DifferenceExpert，一共为四个专家。

FeatureGatingExpert 对每个 spot、每个 latent dimension 计算跨组学 gate，输出只依赖同一个 spot 的两个组学表示，不进行跨节点聚合。以此，能够避免 cross-node attention 可能带来的 majority-domain pooling bias，从而更有利于保留小空间域和边界区域，

如式

$$\begin{aligned}\mathbf{m}_i &= \sigma \left(\phi_m \left(\tilde{\mathbf{z}}_i^{(1)} \parallel \tilde{\mathbf{z}}_i^{(2)} \right) \right), \\ \mathbf{a}_i &= \mathbf{m}_i \odot \tilde{\mathbf{z}}_i^{(1)} + (1 - \mathbf{m}_i) \odot \tilde{\mathbf{z}}_i^{(2)}, \\ \mathbf{e}_i^{(0)} &= \mathbf{a}_i + \phi_{ref}(\mathbf{a}_i)\end{aligned}\quad (17)$$

其中, $\phi_m(\cdot)$ 表示 feature-gating network, $\mathbf{m}_i \in (0, 1)^d$ 是第 i 个 spot 的逐维跨组学门控向量。

$\mathbf{a}_i$ 是根据门控向量 $\mathbf{m}_i$ 得到的, 它表示, 当某一维的 m_{il} 较大时, 该维度更依赖第一个组学; 当 m_{il} 较小时, 该维度更依赖第二个组学。剩余三个专家统一表示为式18:

$$\begin{aligned}\mathbf{e}_i^{(1)} &= \phi_h \left(\tilde{\mathbf{z}}_i^{(1)} \odot \tilde{\mathbf{z}}_i^{(2)} \right), \\ \mathbf{e}_i^{(2)} &= \eta \tilde{\mathbf{z}}_i^{(1)} + (1 - \eta) \tilde{\mathbf{z}}_i^{(2)} + \phi_v \left(\eta \tilde{\mathbf{z}}_i^{(1)} + (1 - \eta) \tilde{\mathbf{z}}_i^{(2)} \right), \\ \mathbf{e}_i^{(3)} &= \phi_d \left(\frac{\tilde{\mathbf{z}}_i^{(1)} + \tilde{\mathbf{z}}_i^{(2)}}{2} \parallel \phi_\Delta \left(\left| \tilde{\mathbf{z}}_i^{(1)} - \tilde{\mathbf{z}}_i^{(2)} \right| \right) \right),\end{aligned}\quad (18)$$

其中, $\mathbf{e}_i^{(1)}$ 是 HadamardExpert, 关注两个组学在同一维度上的一致性;

$\mathbf{e}_i^{(2)}$ 是 VarianceExpert, 其中 η 根据 latent embedding 的全局方差, 估计相对可靠性, 提供一个稳定的 variance-weighted fusion path, 用作稳定的 fallback 表示。表示为 $\mathbf{z}_{var,i} = \eta \tilde{\mathbf{z}}_i^{(1)} + (1 - \eta) \tilde{\mathbf{z}}_i^{(2)}$ 其中, η 表示两个组学的相对可靠性, 根据全局方差计算。

$\mathbf{e}_i^{(3)}$ 是 DifferenceExpert, 它同时利用组学间的平均表示和绝对差异表示, 用于建模跨组学差异。

$\phi_h(\cdot)$ 、 $\phi_v(\cdot)$ 、 $\phi_d(\cdot)$ 和 $\phi_\Delta(\cdot)$ 均表示专家内部的可学习变换。这三个专家分别对应 agreement、reliability 和 disagreement 三类跨组学交互模式, 与 FeatureGating-Expert 共同构成具有多种归纳偏置的专家集合。在全部计算完毕后, 专家聚合为 $\mathbf{z}_{moe,i} = \mathbf{W}_o \sum_{e=0}^{E-1} g_{ie} \mathbf{e}_i^{(e)}$, 并与先前的 $\mathbf{z}_{var,i}$ 进行残差融合。SMEM 并不完全依赖 MoE 输出, 通过此种方法, 避免 MoE routing 在训练初期不稳定时完全主导 integrated embedding。

为了缓解 expert collapse, 我们设计了 load-balancing loss, 防止绝大多数 spots 被分配给同一个专家, 导致其他专家无法充分训练。它是保证专家发生功能分化的重要机制。平均 soft routing probability 可以表示为 $f_e = \frac{1}{N} \sum_{i=1}^N g_{ie}$, 第 e 个专家被选为 dominant expert 的比例为 $p_e = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(e = \arg \max_j g_{ij})$ 。MoE load-balancing loss 如

$$\mathcal{L}_{bal} = E \sum_{e=0}^{E-1} f_e p_e \quad (19)$$

所示。

Results 部分最好配合 *expert usage heatmap*、*dominant expert spatial map* 和 *routing entropy map* 展示该损失确实促使不同专家在不同空间区域发挥作用。

D. 稳定性感知聚类优化

在重构预训练之后, 为了进一步优化潜在空间, 我们设计了稳定性感知深度聚类目标。

在标准 DEC 聚类中, 仅依赖融合表征, 为了改善这一点, SMEM 考虑了融合嵌入与两个特定模态的嵌入, 同时优化了不平衡空间域的训练, 防止发生聚类坍塌。

设 $\mathbf{Z}^{(0)} = \mathbf{Z} \in \mathbb{R}^{N \times d}$ 表示由 MA-MoE 模块输出的融合表征。并设 $\mathbf{Z}^{(1)} = \tilde{\mathbf{Z}}^{(1)}$ 与 $\mathbf{Z}^{(2)} = \tilde{\mathbf{Z}}^{(2)}$, 即两个模态的表征。我们通过 K-means 算法来初始化聚类中心 $\{\mu_k\}_{k=1}^K$:

$$\eta = \frac{\text{Var}(\tilde{\mathbf{Z}}^{(1)})}{\text{Var}(\tilde{\mathbf{Z}}^{(1)}) + \text{Var}(\tilde{\mathbf{Z}}^{(2)}) + \epsilon}, \quad (20)$$

其中 $\mathbf{z}_{var} = \eta \tilde{\mathbf{Z}}^{(1)} + (1 - \eta) \tilde{\mathbf{Z}}^{(2)}$ 。

同时, 对于每个分支 $b \in \{0, 1, 2\}$, SMEM 使用学生 t 分布 (Student's t -distribution) 计算空间位点 i 到聚类 k 的软分配:

$$q_{ik}^{(b)} = \frac{\left(1 + \|\mathbf{z}_i^{(b)} - \mu_k\|_2^2\right)^{-1}}{\sum_{k'=1}^K \left(1 + \|\mathbf{z}_i^{(b)} - \mu_{k'}\|_2^2\right)^{-1}} \quad (21)$$

可以看到, $q_{ik}^{(0)}$ 由融合嵌入计算得出, 而 $q_{ik}^{(1)}$ 和 $q_{ik}^{(2)}$ 则使用相同的聚类中心, 由两个特定模态嵌入计算得出。

1. Target distribution

以 DEC 的聚类方法为基础, 我们基于融合分配 $\mathbf{Q}^{(0)}$ 构建一个锐化目标分布:

$$p_{ik} = \frac{(q_{ik}^{(0)})^2 / f_k}{\sum_{k'=1}^K (q_{ik'}^{(0)})^2 / f_{k'}} \quad (22)$$

其中 $f_k = \sum_{i=1}^N q_{ik}^{(0)}$ 为第 k 个簇的软分配频率。目标分布通过对软分配概率取平方, 使得模型偏向高置信度的分配; 同时对聚类频率进行归一化, 抑制簇规模的差异对训练目标的影响, 从而削弱大型聚类的主导地位, 促进各簇间更为均衡的表示学习。

2. Q-mix warm-up

在融合潜在空间尚未组织良好的情况下, 如果强制要求融合分配与特定模态分配之间保持一致, 则会导致

聚类稳定性大大下降。因此，SMEM 引入了一种渐进式的 Q-mix 预热策略，其公式表示为

$$\bar{q}_{ik}^{(t)} = (1 - \alpha_t)q_{ik}^{(0)} + \frac{\alpha_t}{2} (q_{ik}^{(1)} + q_{ik}^{(2)}), \quad (23)$$

其中

$$\alpha_t = \alpha_q \min \left(1, \frac{t}{T_w} \right). \quad (24)$$

此处， α_q 为最大跨分支的混合权重， T_w 为预热持续时间。在早期阶段，聚类损失主要依赖于融合分支。随着训练的进行，特定模态的分配被逐渐引入，以提供预热的效果，逐步抑制少数分布域。

在这里，聚类损失定义为：

$$\mathcal{L}_{\text{qmix}} = \frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K p_{ik} \log \frac{p_{ik}}{\bar{q}_{ik}^{(t)} + \epsilon} \quad (25)$$

3. Cluster-unit regularization

组织切片中的空间域通常高度不平衡，标准聚类目标可能将可忽略的概率质量分配给小簇，从而产生不活跃或几乎为空的聚类。为了缓解这一问题，我们引入了聚类单元使用率正则化项。定义一个聚类 k ，其预期使用率定义为：

$$\bar{u}_k = \frac{1}{N} \sum_{i=1}^N q_{ik}^{(0)} \quad (26)$$

给定最小聚类大小阈值 $n_{\min}$ ，我们定义 $\pi_{\min} = n_{\min}/N$ ，并且仅对预期分配质量低于此阈值的聚类进行惩罚：

$$\mathcal{L}_{\text{cur}} = \frac{1}{K} \sum_{k=1}^K \frac{\max(0, \pi_{\min} - \bar{u}_k)}{\pi_{\min} + \epsilon} \quad (27)$$

与均匀性正则化不同，该损失公式并不强制所有聚类具有相同的大小。相反，它仅在某个聚类未被充分使用时才会被激活，这使其非常适用于大小区域自然共存的不平衡空间域。

4. Dead-cluster reinitialization

为应对深度聚类中常见的簇退化问题（死簇/空簇），我们设计了死簇重初始化机制：经过固定的 epoch 后，模型检查各簇的硬分配规模，若某簇分配的点数少于 10，则将该簇中心重新设置，并重置对应 Adam 优化器动量，确保重初始化后的中心能稳定收敛。

受到 K-means++ 的重播种 (reseed) 机制启发，在训练轮数 T_{end} 之前，每隔 T_r 轮，我们计算硬分配计数：

$$n_k^{(t)} = \sum_{i=1}^N \mathbb{I} \left[k = \arg \max_j q_{ij}^{(0)} \right] \quad (28)$$

其中，如果某个聚类的硬分配计数小于 $n_{\min}$ ，则将其视为死亡聚类 $\mathcal{D}_t = \{k \mid n_k^{(t)} < n_{\min}\}$ 。

对于最远点策略 (farthest-point strategy)，我们首先定义存活聚类集合 $\mathcal{A}_t = \{1, \dots, K\} \setminus \mathcal{D}_t$ 。根据每个空间位点到最近存活中心的距离为其打分：

$$s_i = \min_{a \in \mathcal{A}_t} \|\mathbf{z}_i^{(0)} - \boldsymbol{\mu}_a\|_2^2 \quad (29)$$

选择得分最大的空间位点作为新的种子点，并将死亡中心更新为 $\boldsymbol{\mu}_{d_j} \leftarrow \mathbf{z}_{i_j}^{(0)}$ ， $d_j \in \mathcal{D}_t$ 。

通过此机制，促使不活跃的聚类中心远离存活聚类，从而防止聚类坍塌。在实际训练中，重新初始化的聚类中心的优化器动量 (optimizer moments) 也会被重置，以稳定后续的更新。

最终的训练目标为：

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \lambda_{\text{kl}} \mathcal{L}_{\text{qmix}} + \lambda_{\text{con}} \mathcal{L}_{\text{con}} + \lambda_{\text{cur}} \mathcal{L}_{\text{cur}} + \lambda_{\text{bal}} \mathcal{L}_{\text{bal}},$$

其中 $\mathcal{L}_{\text{rec}}$ 为图与特征重构损失， $\mathcal{L}_{\text{con}}$ 强制融合嵌入与特定模态嵌入之间保持着一致：

$$\mathcal{L}_{\text{con}} = \frac{1}{N} \sum_{i=1}^N \left(\|\mathbf{z}_i^{(0)} - \mathbf{z}_i^{(1)}\|_2^2 + \|\mathbf{z}_i^{(0)} - \mathbf{z}_i^{(2)}\|_2^2 \right),$$

其中 $\mathcal{L}_{\text{bal}}$ 为用于避免专家坍塌 (expert collapse) 的 MoE 损失。死亡聚类重初始化是一种优化阶段的中心管理策略，用于定期挽救不活跃的聚类。

IV. EXPERIMENTS

我们设计了一套全面的实验方案，从四个互补的角度评估 SMEM：聚类准确性、空间域保持能力、跨组学融合质量和优化稳定性。首先，我们在有标注的空间转录组-蛋白质组数据集上，与其他先进方法进行对比试验，其次，我们对空间域分配和低维嵌入进行可视化，以评估所学表示是否保持了组织结构。第三，我们进行消融实验，用以评估前文中所提方法的贡献。最后，通过标记特征，分析所识别空间域的生物学相关性。

A. Datasets

我们在三个公开空间转录组-蛋白质组数据集上评估了 SMEM 的性能，包括两个有人工标注的人类淋巴结切片 A1 和 D1，以及一个无人工标注的小鼠乳腺癌切片。主要基准数据集为人类淋巴结 D1 切片，包含 3359 个空间点、18,085 个基因、31 个 ADT 特征和 11 个标注的组织/细胞类型区域；为进一步评估泛化能力，

我们还考虑了人类淋巴结 A1 切片和小鼠乳腺癌。对于有标注的数据集，手动标注仅用于评估，不用于表示学习；对于无标注数据集，我们使用了小鼠乳腺癌数据集，通过标记特征分析和下游生物学解释，来评估所识别簇的生物学合理性。具体的信息对比如表 I 所示：

表 I
STATISTICS OF BENCHMARK SPATIAL MULTI-OMICS DATASETS.

Dataset	Spots	Genes	ADTs	Clusters
Human lymph node A1	3484	18,085	31	10
Human lymph node D1	3359	18,085	31	11
Mouse breast cancer	1978	32,286	32	-

B. Compared methods

为全面评估 SMEM 的有效性，我们将其与八种代表性方法进行比较，其中包括经典的组学整合方法 SpatialGlue、SpaFusion 和 SpaMICS。它们同时利用空间坐标和多组学测量，所有方法均使用原论文或官方教程推荐参数运行，并在相同数据预处理和聚类数设置下进行比较。其中一些方法的简要介绍如下：

GATCL：一种结合了图注意力网络（Graph Attention Network）与对比学习（Contrastive Learning）的深度深度学习框架，通过对比学习提升空间结构域的识别精度；

MOFA+：一种基于统计学的分析框架，利用变分推断（variational inference）为多组学数据的整合构建低维潜在表示；

MultiVI：一种用于分析多组学数据的概率模型，该模型能够有效改善在单模态数据集上的联合概率推断效果；

TotalVI：一种针对 CITE-seq 数据设计的模型，该模型通过学习配对的 RNA 与蛋白质测量数据的联合概率表示，来实现多组学特征的有效整合；

scMIC：一种深度信息融合框架。该方法采用协同学习（collaborative learning）策略，专门用于单细胞多组学数据的聚类分析；

SpatialGlue：一种采用双重注意力机制（dual-attention mechanisms）的图神经网络模型；

SpaFusion：该框架结合了图自编码器与 Transformer 模块，从局部和全局视角提取潜在特征；此外，它利用共识聚类（consensus clustering）策略实现精确的细胞分型；

SpaMICS：一种深度子空间学习（Deep Subspace Learning）框架。该方法通过在多个组学层之间解耦（disentangle）共享的一致性特征与模态特异性的互补特征，来有效提升空间多组学数据的空间域识别能力。

C. Data preprocessing 与参数设定

在处理 Human lymph node A1 和 Human lymph node D1 数据集时，我们延续并采用了如下的数据预处理：对于 RNA 模态，我们移除了在少于 10 个细胞中表达的基因，使用 Seurat v3 策略选取前 3000 个高变异基因。其中，计数矩阵按每个点的总计数 10^4 归一化，进行 log 转换与标准化后投影至 100 维主成分空间；对于 ADT 模态，我们对每个点施加中心化对数比（CLR）归一化，随后标准化并执行 PCA 降维至 $d_{\text{ADT}} - 1$ 维（其中 d_{ADT} 为蛋白标记物数目）。

在图的构建方面，对于每个模态，SMEM 构建了两张互补图。空间图基于物理点坐标，使用 $k = 9$ 的 k 近邻策略构建；特征图在模态特定的 PCA 空间中使用 $k = 20$ 的 k 近邻构建。

此外，对于每个模态的特征图，我们额外计算三节点 motif 共现矩阵 $\mathbf{M}_t$ ，该矩阵统计特征图中所有三角形闭合的频次并同样进行对称归一化。最终输入编码器的特征图可为学习参数加权的混合： $\tilde{\mathbf{A}}_{\text{feat}} = k_1 \cdot \mathbf{A}_{\text{feat}} + k_2 \cdot \mathbf{M}_t$ ，其中 k_1, k_2 为可训练标量参数，初始化为 0.5。

所有实验在单块 NVIDIA GPU 上运行（CUDA 加速），使用 PyTorch 2.2.1 实现。具体的参数设定见表 II：

D. 评估指标

对于包含人工标注数据的基准数据集，我们采用多种指标全面评估空间域识别的性能。令 $\mathbf{y} = \{y_i\}_{i=1}^N$ 表示由人工标注的参考标签， $\hat{\mathbf{y}} = \{\hat{y}_i\}_{i=1}^N$ 表示模型预测的空间结构域簇标签，其中 N 为切片中的空间位点（spots）总数。具体描述如下：

a) 调整兰德系数：ARI 是目前空间组学 Benchmark 中公认的核心指标。它引入了期望校正，因此能够客观地反应多模态特征融合的效果。

ARI 的定义如下：

$$\text{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \frac{\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}}{\binom{N}{2}}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \frac{\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}}{\binom{N}{2}}} \quad (30)$$

表 II
SMEM 主要超参数设定

参数	符号	取值
网络架构		
MoE 专家数	E	4
MoE 隐藏维度	—	128
训练流程		
聚类训练 epoch 数	—	800
学习率	η	10^{-3}
优化器	—	Adam
损失权重		
KL 散度权重	λ_1	1.0
一致性损失权重	λ_2	0.1
重建损失权重	w_{1-6}	均为 1.0
MoE 均衡损失权重	λ_{bal}	0.01
簇使用正则权重	λ_{usage}	0.05
门控噪声乘数	—	1.0
聚类优化		
Q 混合系数	α_{mix}	0.1
Q 混合预热 epoch	—	500
死簇重初始化周期	—	每 50 epoch
最小簇阈值	—	10 个点

其中, n_{ij} 表示同时属于真实类 i 且被分配到预测类 j 的样本数; $a_i = \sum_j n_{ij}$ 和 $b_j = \sum_i n_{ij}$ 分别表示真实类别 i 和预测聚类 j 的总样本数。

b) **F1**: F1 值作为评估指标, 用于评估模型对细小结构域的识别能力:

$$F1 = 2 \times \frac{P \times R}{P + R} \quad (31)$$

P (精确率, Precision) 表示在预测簇中, 正确属于对应真实簇的细胞所占的比例; R (召回率, Recall) 表示在真实簇中, 被准确分配到正确预测簇的细胞所占的比例。

c) **聚类准确率**: ACC 是评估聚类结果与真实标签是否符合的最直接方法, 在利用匈牙利算法 (Hungarian Algorithm) 对聚类标签进行最优一对一映射后, 计算全局的分类正确率。ACC 的定义如下:

$$ACC = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[y_i = \pi^*(\hat{y}_i)] \quad (32)$$

在此公式中, π^* 表示通过匈牙利算法 (Hungarian Algorithm) 求解出的预测标签到真实标签的最优一对一映射函数; $\mathbb{I}[\cdot]$ 为指示函数, 当内部匹配条件成立时取值为 1, 否则取值为 0。

此外, 我们还通过 NMI、AMI、VMS 和 FMS 等多种评估指标, 来全面评估方法的性能。

V. RESULTS

A. 聚类结果

a) **D1 数据集**: 表 ?? 显示了 SMEM 在 D1 数据集上的聚类结果和与其他方法的对比, 包括 ARI、ACC、AMI、F1 和 FMS 等指标。可以看出, SMEM 的效果显著且在多种指标上表现出领先效果, 例如

b) **D1 数据集**:

c) **D1 数据集**:

B. 可视化

a) **D1 数据集**:

b) **A1 数据集**:

c) **小鼠乳腺癌数据集**:

C. 生物学分析

a) **D1 数据集**:

b) **A1 数据集**:

c) **小鼠乳腺癌数据集**: