# 基于 Stage 扫描机制的 Vision RWKV 让医学影像分割轻量而高效

sora*, Zhendong Li*
*Ningxia University
Email: kyochilian@gmail.com, lizhendong@nxu.edu.cn

***Abstract*—基于 Transformer 的分割框架是当前医学影像分割的主流方法，能够构建全局关系。然而，在需要高精度与高分辨率的医学图像分割中，Transformer 计算复杂度高，应用有限。最近的 RWKV 模型降低了空间聚合复杂度并具备全局处理能力，但其在视觉领域存在长程建模羸弱的问题，贪吃蛇效应突出，同时循环嵌套机制在分割领域中的解码性能不足。为了解决这些问题，我们提出了一种基于 Vision RWKV 的分割框架 RWKV-SSS，该框架在具有较低复杂度的同时具备了全局建模能力。为了增强 RWKV 的长程空间连续性，我们设计了一种 Stage 扫描机制，该机制将图像分为全局 block 与局部 block，根据不同 Stage 的编码器，相应调整扫描比例，将全局与局部特征融合，大大提升了模型的精度。同时，我们在解码器中构建了上采样模块---，该模块改良了 RWKV 的循环嵌套机制，提升了重建多尺度特征的能力。我们还采用多种方法进一步降低 SSS 的计算复杂度，实现模型的轻量化。（LRFormer 低分辨率自注意力，池化 QKV 等等）实验表明，我们的方法在多个数据集取得优异性能，同时计算复杂度与计算速度显著增强，使其在高精度分割的同时具备轻量化特性。代码开源至：https://github.com/shepherdxu/SCI-winning。**

***Index Terms*—computer vision, semantic segmentation, RWKV, Transformer, lightweight**

## I. Introduction

Semantic Segmentation 是计算机视觉中的一项重要任务，医学影像分割是关键应用之一。它将复杂的医学图像分割成不同的区域，使器官、病灶及注意区域清晰可见，对于医学辅助诊断与治疗具有重要意义。相较于人工，使用计算机视觉技术进行辅助诊断不仅提高了诊断效率，还提升了诊断精度，因此许多方法被提出用于医学影像分割任务。多年来，传统的 ML（机器学习）方法在研究中被广泛应用，如基于图割（Graph Cut）的方法 [4]、随机森林（Random Forest） [5]、支持向量机 (Support Vector Machine, SVM) [6] 以及条件随机场 (Conditional Random Field, CRF) [7] 等。这些方法依赖人工设计的特征提取器，在处理复杂医学图像时存在局限性，由于图像存在模糊、噪声、对比度低等问题，传统方法的准确性和鲁棒性受到限制。

近年来，随着 FCN(Full Convolution Network) [9]、CNN(Convolution Natural Network) [8] 的提出，深度学习方法逐渐代替了传统机器学习方法，语义分割方法的网络深度、特征提取均有了较大提高。随着 Unet [10] 的提出，基于深度学习的分割方法占据了主导地位，通过创新性的 U 型架构，使其成为了语义分割的主流框架，涌现了 Unet++ [?]、Attention-Unet [?] 等方法。2017 年，Google 提出的 Transformer [11] 在自然语言处理（NLP）领域 have maked 深远影响，which 为视觉领域带来了 ViT(Vision Transformer) [12] in 2020，使得计算机视觉领域拥有了全局注意力 (Global Attention) 与自注意力机制 (Self-Attention) [11]，makes better for 全局语义信息提取，改善了 CNN 的不足 [?]。** 等人提出了 TransUnet [?]，将 Unet 与 CNN 和 Transformer 结合起来，使得医学图像分割方法的精度大大提高。

目前，主流的方法主要遵循 TransUnet 的思路，在上述深度学习方法中作修改 [?]，将 CNN 作为局部注意力提取 [?]，为了进行更高精度的分辨，将 Transformer 作为把握全局特征的模块，采用类似 Unet 的上下采样与 skip connection 的结构，达到期望的分割效果 [?]。然而，医学图像具有低对比度、高分辨率、目标边界模糊等诸多问题 [?]，对于自注意力机制来说缺乏友好，往往需要花费大量的参数来提取低对比度医学特征，牺牲了时间与空间性能 [?]，同时自注意力机制具有平方复杂度，高分辨率的医学图像会使计算复杂度大大增加，高参数网络也不适宜部署在医院等边缘设备，这些限制了 Transformer 在医学图像上的直接应用 [?] [?]。

一些研究人员研究改善这种情况。**** 等人提出了 Linear Transformer [?]，** 等人在 20xx 年提出了 Mamba [?] 模型，不同于 Transformer 的框架，他们均通过将自注意力机制的复杂度改为线性，从而缓解计算复杂度问题。然而，事实证明，线性复杂度的 Transformer 变体总会牺牲分割精度与准确率，而 Mamba 模型的长序列建模（SSM）也不适用于视觉问题 [?]。鉴于医学影像中 3D 体数据、MRI 与 CT 等高分辨率数据普遍存在，且存在高精度的像素级分割要求，实践中还需要考虑医院边缘设备的部署问题，如何平衡精度与效率、参数与性能，成为急需解决的问题。

Recurrent Weighted Key-Value(RWKV) [?] 的出现引起了我们的关注。其在 NLP 领域的线性复杂度注意力机制，不同于 Transformer 的结构，使其有价值迁移到视觉任务上。Vision RWKV(VRWKV) [?] 尝试了该问题，并针对图像输入进行了结构改进，展现出优异的计算效率与模型精度，** 等人提出了 BSBP-RWKV [?]，首次将 RWKV 应用于医学图像任务，一些研究如 RWKV-Unet [?] 将 VRWKV 与 Unet 迁移到医学图像分割任务上。在高分辨率的医学图像任务下，RWKV 优于其他 Transformer 变体与 Mamba 模型，处理医学图像输入时的推理速度更高，且效果更好 [?]。

作为一款线性注意力模型，尽管 RWKV 拥有良好的计算效率与精度，但迁移到图像任务上，还是有不可避免的问题。RWKV 本质是沿序列建模的状态空间式结构，针对离散数据 (如自然语言处理) 的处理过程是固定的，自注意力的处理方式也是一维的。面对连续且二维的图像，基于 RWKV 的图像处理方法是将图像分块，并延展为一维，导致了空间连续性上的破坏 [?]。

在注意力提取过程中，RWKV 使用一维的方式在二维

图像上进行特征提取，我们称其为贪吃蛇效应 **??**。RWKV 的扫描方式是固定的，在图像任务中，注意力的权重往往动态且多变，固定的扫描方式往往会将注意力分片 [**?**]。(如图 **??**)。若提取到更深层次，图像的特征更容易模糊，RWKV 容易将模糊的特征边缘分离，进行分片扫描，导致容易导致器官边缘、细小病灶（如微小息肉、早期病变区）分割不精细，而这是医学图像分割的要求之一 (如图 **??**)。同时，医学方向涉及三维数据，在三维医学图像中，边界分割、注意力分片的现象将会更为突出，这为 RWKV 向医学领域的适配带来了挑战 [**?**]。

为此，很多工作进行了改进。U-RWKV 提出了方向自适应 RWKV 模块 [**?**]，改进了 RWKV 的扫描方式，使其不仅仅局限于一维层面的注意力叠加。Zig-RiR [**?**] 提出了 ZigZag 的扫描方案，试图解决 RWKV 扫描的空间连续性问题。然而，其带来了诸多问题：扫描缺乏对图像的动态调整，导致其训练过程不稳定，且不同器官之间的精度存在较大差异 **??**; 同时，贪吃蛇效应仍然存在；两者工作的上采样过于简单，导致恢复特征分辨率时的精度不足，无法满足医学图像像素级分割的要求。

我们的研究致力于解决该问题。受到 Vision RWKV [**?**] 以及 URWKV [**?**] 的启发，我们提出了一种基于 RWKV 的 U 型架构 Stage Scan Segmentation，该架构具备完备的编码器-解码器，在保持了 RWKV 的长程依赖和线性复杂度的同时，增强了局部细节的表达与分割的精度。具体来说，我们采用了 Bi-WKV，一种线性注意力，作为我们的注意力核心 [**?**]，并提出了 stage scan，一种基于 encoder 层次的扫描机制，根据不同层次的编码器，调整扫描方向与比例。为了解决 RWKV 的空间连续性问题，SSS 将一个维度的模块设置为全局 block 与局部 block，分别提取全局与局部特征。在一开始，输入特征的分辨率与 H、W 较大，特征比较分散，噪声较多，需要我们进行更多的分块扫描。随着编码器的 Stage 增加，输入特征的细节将会更多更集中，图像的分块数也会随着层数的增加而减少 **??**，以此把握全局的注意力。在一个模块的前端，我们使用全局 block，较大的 Stage 分块，进行初步的特征提取。随后，采用残差机制 [**?**] 将提取后的全局权重与原特征加和。局部 block 接收加和后的权重，将 stage 分块进一步增大，进行局部的特征提取。同时，为了缓解贪吃蛇效应 **??**，我们改进了四项 token 位移 [**?**]，根据已确定的扫描机制，动态调整扫描位移的方向。低参数量 **??**。其次，我们对 RWKV 的 WKV 进行适当池化 [**?**]，实现进一步的轻量化。最后，我们在上采样阶段实现动态上采样 [**?**]，而不仅仅进行反卷积，进一步保留了分割结果的精度与细节。通过这种方式，SSS 获得优于其他方法的特征捕捉能力 **??**，增强了对边缘的分割能力和鲁棒性，并发挥了 RWKV 应有的计算效率与低参数量。

总的来说，我们的贡献有：

1. 使用 VRWKV 作为分割的核心方法，达到了线性复杂度与注意力精度的平衡；

2. 提出了基于 Stage 的 Scan 方法，缓解了贪吃蛇效应，有效提取全局特征与局部特征；

3. 在对多个 2d 以及 3d 数据集中，SSS 的效果优于目前许多最先进的方法，同时参数量降低了 20%,GPU 占用降低了 23% **??**。

待写：上采样问题轻量化问题所谓的动态?

加入 RWKV 扫描后的热力图，表示注意力在图像上的衰减

## II. Related Works

### *A.* 医学图像分割

目前，基于深度学习的医学图像分割网络是主流，且很多的先进方法均基于 CNN 和 Transformer 的变体得来。

*1. 纯净的 CNN*。最具代表性的为 Unet [10]。UNet 的优势在于编码器-解码器的结构，并通过跳跃连接有效减少信息在传输过程中的损失，实现对复杂医学图像中细微结构的精准分割。部分研究者对 Unet 进行了改进，例如 UNet++、UNet3+、3D UNET 和 Attention Unet 等等。但是，卷积核的有限感受野难以捕捉远程关系和远程关系，限制了模型的分割性能。同时，在面对大尺寸医学图像或三维图像时，UNet 的性能往往不足，导致细节的丢失和全局能力的不足。

*2. 纯净的 Transformer*。Transformer 的核心机制 self-attention 使其能够把握全局上下文关系，该机制被大量应用至计算机视觉领域，例如 ViT。Transformer 克服了 CNN 在处理长程依赖关系时的不足，并将每个图像块作为输入序列传递到 Transformer 编码器，以获得图像的全局表示。Liu [**?**] 等人设计了 SwinTransformer 架构，该架构针对图像分割和目标检测任务设计，并在医学影像分割上取得了不错的成绩。Cao [**?**] 等人将 Unet 与 Transformer 架构融合，设计了 Swin-Unet，提升了医学影像的分割精度和泛化能力。Lin [**?**] 等人进行了进一步的改进，采用双尺度编码器子网来提取不同语义尺度的特征，建立不同尺度之间的依赖关系。采用纯净 Transformer 的模型对医学图像的精度和鲁棒性较好，但其复杂度较高，精细局部特征提取能力不足，限制了其在医学图像中的应用。

*3. 将 CNN 与 Transformer 结合*，利用 CNN 在捕捉局部特征上的优越性以及 Transformer 对全局依赖性的处理能力。具有代表性的是 TransUNet [**?**]、CoTr [**?**]、UTNet [**?**] 和 Transfuse [**?**] 网络等。这些网络通过各种串行、并行的方式将 CNN 与 Transformer 结合到一起，整合了全局与局部特征，使精度进一步提高。该方法的核心问题是：模型计算复杂度较高。Transformer 模块处理图像任务需要将图像序列化，形成较长的序列。尽管 ViT 提出了图像块序列，但图像切割后计算量仍然较大；混合模型需要同时维护 UNet 的卷积层和高复杂度的自注意力机制，虽然增强了细节的特征提取能力，但模型的参数和推理速度均显著降低，无法部署在医院的大量边缘及低算力设备中，应用有限。

改进 [**?**]。

### *B.* 线性注意力

线性注意力致力于打破二次方级的注意力复杂度瓶颈，使注意力机制更加高效，并催生出了一系列 Transformer 变体和非 Transformer 架构。

*1. Transformer 变体*。一些针对于 Transformer 的改进如 Linear Transformer [**?**]，提出了特征映射的概念，用以替代 Softmax，将 Attention 机制视为 Linear RNN 的过程。** 等人提出了 Performer [**?**]，引入了正交随机特征 (Orthogonal Random Features, ORF)，使其接近 Softmax 的效果。二者均通过对 softmax 函数效果的改进，进而达到线性注意力的目的。以此为基础，Han [**?**] 等人提

出了 Flatten Transformer，设计了一种聚焦线性注意力 (Focused Linear Attention)，改善了空间特征的完整性，完善了线性注意力在视觉领域的应用。

*2. the new wave*。如经典的 mamba [?] 模型，其引入了选择性扫描机制（Selective Scan），让模型能够根据输入内容动态压缩记忆。U-Mamba [?]、Swin-UMamba [?]、VM-UNet [?] 等方法探索了 Mamba 模型在医学图像分割领域的运用，将 Mamba 模型与 SSM 的思想整合进了分割领域当中，并进行了针对性的优化。然而，SSM 的核心机制致使其无法有效建模初窗口之外的全局上下文信息，基于 SSM 的视觉模型与最先进的卷积模型和基于注意力的模型相比，表现不佳，导致其并不适合视觉任务 [?]，且其运行速度往往以准确率为代价。

### C. RWKV

最近提出的 Receptance Weighted Key Value(RWKV) [?] 是不同于 Transformer 的线性架构，擅长处理长序列关系与自回归任务，在 NLP 领域效果优良，并催生出在视觉领域的一系列运用 [?] [?]。同时，一些研究人员，也探索了 RWKV 在医学分割领域的运用 [?] [?] [?]。

以此为契机，我们继续完善专精于医学分割的 RWKV。经过研究，我们发现，RWKV 不适宜直接运用至分割任务中，因为原始的因果感受野的机制，在图像任务中表现不好，同时，各种针对图像分割的改进，没有缓解贪吃蛇效应**??**，这导致边界分割模糊，没有达到像素级分割的要求**??**，全局注意力的上下文关系也比较割裂。为了解决该问题，我们提出了 Stage scan structure，一种基于 Stage 的 RWKV 扫描方法，并将一次处理分为全局 block 和局部 block，以此，针对特征信息的大小，进行精准的提取，保留了空间连续性。同时，我们改进了 Q-shift，四向位移机制，使其动态调整位移方向，有效缓解贪吃蛇效应。额外地，在原有的 Bi-WKV 基础上，我们利用低分辨率的 WKV 实现进一步的轻量化。

## III. Methods

如图**??**所示，我们整体的网络采用了 U 型架构进行设计，分为下采样、上采样和跳跃连接。其中核心的特征提取在下 · 采样中。整体而言，对于一张待分割的二维医学图像，首先经过 stem，在网络的初始部分，以进行早期的特征提取与图像分块。其次，网络将分块的图像送进 encoder 中，经过全局 SS 和局部 SS，不断增加网络深度并提取分割特征。在此期间，基于 Stage 的扫描机制和 Dynamic Q-shift 将灵活处理分割精度与边界。通过通用的上采样器，最终输出完整的分割结果。

### A. Stem 与预处理

直接使用原始像素 pixel-level 会导致序列过长，提高计算度和低频噪声的出现概率 [?]，因此要对输入的图片进行预处理。我们利用卷机的局部归纳偏置，高效地提取初步特征。图像首先会经过一个 3x3 的卷积块，经过一个 batch normalization(BN)，随后进入 GeLU 函数进行激活。这个步骤会进行两次。两次 3x3 stride=2 卷积均采用 same padding，从而保证输出尺寸为 $\frac{H}{4} \times \frac{W}{4}$。

在两步卷积过程中，图像的空间分辨率会快速缩小，导致在一开始容易丢失边缘细节信息，不利于高精度的语义分割，因此，在初始输入中，我们引入残差连接 [?] 将输入图像分枝，送入分枝的 3x3 卷积中，与一个 batch norm，再与原模块进行常规加权，在深度不变的情况下增强了特征传递。

定义一张输入二维图像为 $X_{in} \in \mathbb{R}^{H \times W \times C_{in}}$。对于医学 CT/MRI 图像来说，通常 $H = W = 256, C_{in} = 1$。stem 模块的卷积核大小 $k = 3$, 步长 $s = 2$，经过 stem 模块后，初始特征图 $F_0 \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4} \times C_0}$，$C_0 = 64$。可以看出，该模块的总下采样率 $S = 4$，Stage i $\in \{1, ..., 4\}$。

图像的初步序列化过程被集中到 Stage scan structure 中。

### B. Stage Scan Structure

初步处理后，我们将特征图分为 global branch 和 local branch，送入 Stage Scan Structure(SSS) 模块中。SSS 模块由多个 Stage 串联组成，每个 Stage 包含若干 Bi-WKV 块。

*1. Multi-Granularity Windows.*

特征图 $F_i$ 进入 encoder 后，我们对其进行分块，以便于进行特征提取。对于 global branch 与 local branch，我们采用不同窗口粒度的分块方法。global branch 旨在捕捉长距离依赖，window size 较大，block 数量较少，序列短；local branch 旨在捕捉局部细节，window size 较小，block 数量较多，序列长**??**。这种不同 Granularity 的方法使得模型能够在不同尺度上捕捉图像的全局与局部特征，提升了分割的精度。

可以看出，对于 stem 输入的同一张原始图像 $F$，global branch 的初始窗口分块可以表示为

$$F_0 \xrightarrow{w_g} \{g_1, g_2, \ldots, g_{m_g}\} \tag{1}$$

其中 $m_g = \frac{H_0}{w_g} \cdot \frac{W_0}{w_g}$. 代表分块数量，$g_i \in \mathbb{R}^{w_g \times w_g \times C_0}$，$w_g$ 代表 global branch 的窗口行列。

同样地，local branch 的初始窗口分块可以表示为

$$F_0 \xrightarrow{w_l} \{\ell_1, \ell_2, \ldots, \ell_{m_\ell}\} \tag{2}$$

其中 $m_\ell = \frac{H_0}{w_l} \cdot \frac{W_0}{w_l}$. 代表分块数量，$\ell_i \in \mathbb{R}^{w_l \times w_l \times C_0}$，$w_l$ 代表 local branch 的窗口行列。$\ell_i \in \mathbb{R}^{w_l \times w_l \times C_i}$，$w_l$ 代表 local branch 的窗口行列。

local branch 的窗口大小小于 global branch 的窗口大小，即 $w_l < w_g$，可以表示为

$$w_l = \frac{w_g}{\kappa} \tag{3}$$

其中 $\kappa$ 为 $g$ 相对于 $l$ 的缩放系数。

*2. Stage-wise Window Mechanism.*

在 SSS 模块中，我们设计了 Stage-wise Window Mechanism，根据不同 Stage 的编码器动态地调整 global branch 与 local branch 的窗口比例与分块数量。

我们设计 SWM 的理由是，随着网络层数加深，特征图的 $H$ 与 $W$ 逐渐减小，分辨率降低，语义信息增强，此时需要更多地关注全局上下文信息；而在浅层语义中，特征图的 $H$ 与 $W$ 较大，分辨率高，噪声较多，需要更多地关注局部细节信息。如图**??**所示，现有的 RWKV 变体如 Zig RiR [?] 与 URWKV [?] 均采用固定的扫描方式，没有适应变化的 stage，导致模型在不同 stage 下的表现不佳，无法更好地提取特征。

为此，全局与局部分枝的窗口，需要根据 Stage 进行调整。在浅层语义中，特征较为分散，噪声与信息较多，需要更多的分块进行扫描提取特征；在 stage 深层语义中，特征图尺寸随着 stage 的增加逐步变小，语义信息变得越来越丰富，此时更需要模型具备理解全局上下文的能力。

以层数 stage $i^\star$ 为变量。设全局窗口边长在所有 stage 上固定为 $w_g = 8$。为实现 Stage-wise 自适应，我们采用分段式比例调度 $\kappa(i)$，从而令局部窗口 $w_l(i) = w_g/\kappa(i)$ 随 stage 变化。公式如下：

$$\kappa(i) = \begin{cases} 4, & i \le i^\star, \\ 2, & i > i^\star, \end{cases} \qquad w_l(i) = \frac{w_g}{\kappa(i)}. \tag{4}$$

则在第 $i \in \{1, ..., 4\}$ 个 stage 上，全局块和局部块分别将特征图 $F_s$ 划分为

$$G_i = \frac{H_i}{w}, w \in \{w_g, w_l\} \tag{5}$$

个非重叠的 blocks，其中 $H_i = W_i$ ，为输入图像的高宽度，序列长度（总块数）$L_i$ 即为 $G_i$ 的平方。

总而言之，在第 $i$ 个 stage 上，Global Branch 可以表示为

$$F_i \xrightarrow{w_g} \{g_{i,1}, \ldots, g_{i,L_i^g}\}, \qquad L_i^g = \frac{H_i}{w_g} \cdot \frac{W_i}{w_g}. \tag{6}$$

Local Branch 可以表示为

$$F_i \xrightarrow{w_l(i)} \{\ell_{i,1}, \ldots, \ell_{i,L_i^\ell}\}, \qquad L_i^\ell = \frac{H_i}{w_l(i)} \cdot \frac{W_i}{w_l(i)}. \tag{7}$$

明显地，$F$ 代表输入的特征图，$L$ 代表序列长度，即分块的总数。

*3. Scan.*

许多线性注意力机制，在计算权重时，依赖 token 的一维序列距离 $|t-i|$，这使得它们对序列的方向和顺序非常敏感。在一张二维图 $\mathbf{F} \in \mathbb{R}^{H\times W\times C}$，当其被序列化为 token 序列时，会产生大量一维序列中相近，但空间二维远离的现象，称之为伪近邻（false neighbors）。注意力机制学习到大量的伪近邻 token，在高权重区域混入不符合二维局部连续性的关系，由此产生只有一维连续性，但没有二维连续性的贪吃蛇效应 **??**。

在不同尺度的特征图上，Bi-WKV [**?**] 进行特征提取。在 Vision RWKV 中，Bi-WKV 由双向（forward/backward）WKV 组成，用于在序列域聚合上下文。在时间步 $t$ 时，生成的双向加权键值聚合结果 $wkv_t$，用公式表示为

$$\begin{aligned} wkv_t &= \text{Bi-WKV}(K_s, V_s)_t \\ &= \frac{\sum_{i=0,i\neq t}^{T-1} e^{-(|t-i|-1)/T\cdot w + k_i} v_i + e^{u+k_t} v_t}{\sum_{i=0,i\neq t}^{T-1} e^{-(|t-i|-1)/T\cdot w + k_i} + e^{u+k_t}} \end{aligned} \tag{8}$$

其中，$K_s$ 和 $V_s$ 分别对应输入序列的键（Key）与值（Value）矩阵；$w$ 是位置相关的衰减因子（Decay factor），用于控制空间或时间距离对权重的影响；$u$ 代表当前位置的增益系数（Bonus factor）；$T$ 为序列的总长度，用于对距离项进行归一化处理。

如式8所示，Bi-WKV 的权重，依赖 token 在一维序列中的相对距离，即为 $|t-i|$. 对每个 token $\mathbf{x}_t$，其主要有效上下文往往集中在序列邻域

$$\mathcal{N}_R(t) = \{i : |i-t| \le R\} \tag{9}$$

其中的 R 为有效的窗口半径。若 $|t-i|$ 小的 token ，在二维平面上也相互邻近，则 Bi-WKV 聚合真实的近邻信息；反之，若短序列窗口在二维上跨越较远距离，则会引入大量伪近邻（false neighbors），表现为只有一维连续性而缺乏二维连续性的“贪吃蛇效应”。

传统 raster 扫描会在行尾发生长跳跃，破坏空间连续性；ZigZag [**?**] 扫描方式，虽能缓解一维序列上的跳跃，但最重要的，二维连续性不足，贪吃蛇效应依然存在。为此，我们提出了两种解决方案：**1.Hilbert 扫描**；**2.Dynamic Q-shift**。

不同于之字扫描与蛇形扫描方式，我们使用 **Hilbert [?] 空间填充曲线（Hilbert space-filling curve）**作为扫描顺序。Hilbert 相比上述方式，能更好地保持 2D 空间的邻近关系。这对医学分割很重要，相邻像素通常属于同一语义类别,Hilbert 扫描将 2D 图像序列化为 1D 时，能让语义连续的区域在序列中也保持连续。Hilbert 是一种空间填充曲线，在不同尺度上具有递归结构，在序列化为 token 后，连续的序列片段，在二维上通常是邻接的，减少了伪近邻现象，避免了换行导致的跳跃**??**。

在 Vision Transformer 及其视觉变体中，使用了 patch embedding + 自注意力机制，token 间并无一维序列关系。但 Bi-WKV 采用序列建模，token 间的相对位置关系对权重计算有重要影响，Hilbert 扫描是具有价值的扫描方式。

在 stage 的 global branch 与 local branch 中，我们采用这种扫描方式。设某 $i$ 的 stage 中的特征图 $F_i \in \mathbb{R}^{H_i\times W_i\times C_i}$，由公式 4-7，定义一个双射在窗口 $w \times w$ 上的 Hilbert 映射为

$$\pi_{\mathrm{H}}^{(i,w)} : \{0, 1, \ldots, L_i(w) - 1\} \to \{0, 1, \ldots, G_i(w) - 1\}^2 \tag{10}$$

其中 $\pi_{\mathrm{H}}^{(i,w)}(t) = (r_t, c_t)$ 给出序号 $t$ 对应的窗口坐标；其逆映射 $(\pi_{\mathrm{H}}^{(i,w)})^{-1}(r, c) = t$ 给出每个窗口在序列中的位置。据此，Hilbert 将二维窗口集合 $\{b_{i,r,c}\}$ 序列化为

$$\mathbf{X}^{(i,w)} = \left[\mathbf{x}_0^{(i,w)}, \ldots, \mathbf{x}_{L_i(w)-1}^{(i,w)}\right] \in \mathbb{R}^{L_i(w)\times d} \tag{11}$$

其中

$$\mathbf{x}_t^{(i,w)} = \phi\big(b_{i,\ \pi_{\mathrm{H}}^{(i,w)}(t)}\big), \quad t = 0, \ldots, L_i(w) - 1 \tag{12}$$

$\phi(\cdot)$ 表示对窗口块的 token 化，输出维度为 $d$。

Hilbert 的曲线构造如下：在一个离散网格 $G \times G$ 上，定义映射 $G = 2^k$：

$$\begin{aligned} \mathcal{H}_k : \{0, 1, \ldots, G^2 - 1\} &\to \{0, 1, \ldots, G - 1\}^2, \\ \mathcal{H}_k(t) &= (r_t, c_t) \end{aligned} \tag{13}$$

若 $k = 1$（$2 \times 2$），$\mathcal{H}_1$ 给出基本遍历顺序；当 $k > 1$ 时，将网格划分为四个 $(G/2) \times (G/2)$ 子象限，对每个象限内使用低阶映射 $\mathcal{H}_{k-1}$ 并施加旋转/翻转变换，使得四段子路径首尾相接且整体连续。

离散连续性可以表示为

$$\|\mathcal{H}_k(t+1) - \mathcal{H}_k(t)\|_1 = 1, \quad t = 0, \ldots, G^2 - 2. \tag{14}$$

可以看出，对半径 $R$ 的序列邻域 $\mathcal{N}_R(t)$，其对应的二维序列通常落在紧凑子块中，相邻的序号在二维上保持邻接状

态。在医学分割过程中，使用 Hilbert 扫描，使 Bi-WKV 的有效上下文（由 $|t-i|$ 控制）更接近二维局部感受野，也就减少了伪近邻现象。

由图**??**，Hilbert 扫描，序列的连续片段主要集中在二维左侧区域。对于医学图像而言，病灶、器官往往集中聚合在某一区域，Hilbert 扫描提高了空间邻近的 token 在序列邻域内出现的概率，减少了伪近邻引入的错误聚合，提升了分割精度。实验表明，在医学图像分割任务中，Hilbert 扫描优于传统的扫描方式以及 S 字形扫描 **??**。

Hilbert 的定义中，要求窗口网格尺寸 $G_i(w) = H_i/w$ 为 $2^k$。对于医学图像来说，$H_i$ 与 $w$ 取值使得 $G_i(w)$ 在各 stage 上均为 $2^k$，无需额外处理。为了提高鲁棒性，若使用了自定义的数据集，当 $G \neq 2^k$ 时，我们为网络添加了处理机制，将网格划分为若干 $2^k \times 2^k$ 子块，每个子块内部使用 Hilbert，子块之间，再进行第二次 Hilbert 扫描，to 拼接。

由图**??**，注意力核心的计算复杂度为

$$O = (2TC). \tag{15}$$

### C. Dynamic Q-shift

虽然改进了 Hilbert 扫描方式，但二维近邻的空间仍是割裂的。贪吃蛇仅仅在序列化时改变了爬行方式，而并没有改善更高维的信息交换。

在 Vision RWKV 中，采用了四向位移机制 (Q-shift) [**?**]，通过对 token 进行四个方向的位移，增强了空间连续性。Q-shift 的公式如下：

$$\begin{aligned} Q_{shifted} = &\ \mathrm{ShiftUp}(Q) + \mathrm{ShiftDown}(Q) \\ &+ \mathrm{ShiftLeft}(Q) + \mathrm{ShiftRight}(Q) \end{aligned} \tag{16}$$

这是对网络从一维语义像二维图像的改进，但是，正如上文所说，这种扫描方式，对于序列的方向与顺序较为敏感。同一张 2D 图像，更换一种扫描顺序，相对空间位置会显著变化，从而影响空间连续性。就像贪吃蛇游戏中，蛇头的移动方向决定了蛇身的走向，而无法关系周围的空间结构与顺序。

在本文网络中，为了缓解贪吃蛇效应，我们对 Q-shift 进行了改良，使其动态调整位移方向。

设第 $i$ 个 stage 中，在窗口尺度 $w \in \{w_g, w_l(i)\}$ 下，块网格尺寸为 $G_i(w) = H_i/w$，序列长度为 $L_i(w) = G_i(w)^2$。由式10的 Hilbert 双射 $\pi_{\mathrm{H}}^{(i,w)}(t) = (r_t, c_t)$，我们可以为每个序号 $t$ 定义其在扫描路径上的“切向”方向（forward tangent）为

$$\mathbf{d}_t = \begin{cases} \pi_{\mathrm{H}}^{(i,w)}(t+1) - \pi_{\mathrm{H}}^{(i,w)}(t), & 0 \le t \le L_i(w) - 2, \\ \pi_{\mathrm{H}}^{(i,w)}(t) - \pi_{\mathrm{H}}^{(i,w)}(t-1), & t = L_i(w) - 1, \end{cases} \tag{17}$$

由 Hilbert 离散连续性 $\|\pi_{\mathrm{H}}^{(i,w)}(t+1) - \pi_{\mathrm{H}}^{(i,w)}(t)\|_1 = 1$ 可知，$\mathbf{d}_t \in \{(\pm 1, 0), (0, \pm 1)\}$，即每一步仅在四邻域中移动一格。

接着，令四个单位方向为

$$\mathbf{e}_\uparrow = (-1, 0), \quad \mathbf{e}_\downarrow = (1, 0), \quad \mathbf{e}_\leftarrow = (0, -1), \quad \mathbf{e}_\rightarrow = (0, 1). \tag{18}$$

对于任意方向 $\delta \in \{\uparrow, \downarrow, \leftarrow, \rightarrow\}$，定义其与扫描切向是否“共线”（即是否属于扫描路径方向）的指示量

$$a_{t,\delta} = |\mathbf{d}_t^\top \mathbf{e}_\delta| \in \{0, 1\}, \tag{19}$$

其中 $a_{t,\delta} = 1$ 表示方向 $\delta$ 与扫描切向平行，而 $a_{t,\delta} = 0$ 表示方向 $\delta$ 与扫描切向正交（位于扫描路径两侧）。

**方向自适应权重。**由于 Bi-WKV 的主要聚合来自序列邻域 $\mathcal{N}_R(t)$（式 (31)），而 $\mathcal{N}_R(t)$ 在二维上天然更偏向扫描切向邻域，因此我们令沿扫描路径方向的位移更弱、非扫描路径（左右侧）方向的位移更强。具体地，构造未归一化权重

$$\tilde{\alpha}_{t,\delta} = \begin{cases} \alpha_\parallel, & a_{t,\delta} = 1, \\ \alpha_\perp, & a_{t,\delta} = 0, \end{cases} \qquad \alpha_\perp > \alpha_\parallel, \tag{20}$$

并进行归一化

$$\alpha_{t,\delta} = \frac{\tilde{\alpha}_{t,\delta}}{\sum_{\delta'} \tilde{\alpha}_{t,\delta'}}. \tag{21}$$

将 $\alpha_{t,\delta}$ 通过 $(r_t, c_t) = \pi_{\mathrm{H}}^{(i,w)}(t)$ 回填到二维网格上，可得权重图 $\alpha_\delta \in \mathbb{R}^{G_i(w) \times G_i(w)}$，即

$$\alpha_\delta(r_t, c_t) = \alpha_{t,\delta}. \tag{22}$$

**Dynamic Q-shift。**设当前分枝（窗口尺度 $w$）下的 Query 张量为 $Q \in \mathbb{R}^{G_i(w) \times G_i(w) \times d}$，则 Dynamic Q-shift 定义为对四向位移结果进行逐位置加权求和：

$$\begin{aligned} Q_{\mathrm{DQS}} = &\ \alpha_\uparrow \odot \mathrm{ShiftUp}(Q) + \alpha_\downarrow \odot \mathrm{ShiftDown}(Q) \\ &+ \alpha_\leftarrow \odot \mathrm{ShiftLeft}(Q) + \alpha_\rightarrow \odot \mathrm{ShiftRight}(Q), \end{aligned} \tag{23}$$

其中 $\odot$ 表示逐位置乘法。式23 在形式上保持了 Vision RWKV 的四向位移结构，但通过式17–21 使位移方向随扫描路径动态变化：在扫描切向上施加更小的位移权重 $\alpha_\parallel$，而对扫描法向施加更大的位移权重 $\alpha_\perp$，增强二维近邻的信息交换，从而进一步缓解贪吃蛇效应。

需要强调的是，$\alpha_\perp, \alpha_\parallel$ 不引入额外的注意力计算，仅产生常数级的逐点乘法开销，并且由于其仅由扫描顺序决定，在给定 $i, w$ 后可预计算，因此对推理速度影响较小。

### D. Core WKV

在原始的 Vision RWKV 中，RWKV 块分为 Spatial Mix 与 Channel Mix，其中 Spatial Mix 是 RWKV 的注意力的核心，所谓的 Hilbert 扫描也在此改进。

SSS 的 RWKV 块如下图所示**??**。在 Spatial Mix 中，经过 Dynamic Q-shift 的位移，$R_s$ 被送入 Squared ReLU 中，而 $K_s$ 与 $V_s$ 经过 Hilbert scan 后被送入 Bi-WKV 中。

如图**??**所示，$K_s$ 与 $V_s$ 总共经历两次扫描。第一次经历正方向的 Hilbert 扫描后，被送入第一道注意力模块中，为 $wkv_1$。随后将 Hilbert Scan 的角度旋转 90 度，经历第一次扫描后的 $K_s$ 与 $wkv_1$ 再次进入 WKV 模块中，并输出最终的 WKV 模块 $wkv_2$。

在 Channel Mix 中，我们遵循 Vision RWKV 的结构首先进入 Dynamic Q-shift。随后的 $R_c$ 与 $V_c$ 分别经过 Sigmoid 以及 Squared ReLU，经过 Element-wise Multiplication 之后，再经过一道简单的 Norm 形成最终的输出。这就是整个 Stage Scan Structure WKV 块的整体结构。

其中，wkv 块的计算方式可以表示为

## IV. Experiments

实验结果。与 ZigRiR 一致。

TABLE I: Top-1 accuracy (%) on CIFAR-10 under different sparsities.

| Method | 90% sparsity | 95% sparsity |
|---|---|---|
| Baseline | 93.5 | 91.2 |
| Magnitude [1] | 92.8 | 89.7 |
| DST (ours) | **94.1** | **92.3** |

## V. Conclusion

We presented a simple yet effective DST framework that dynamically adjusts sparse connectivity during training. Future work includes extending DST to transformer architectures.

## Acknowledgment

This work was supported by the National Natural Science Foundation of China under Grant 62XXXXXX.

## References

[1] S. Han, J. Pool, J. Tran, and W. Dally, "Learning both weights and connections for efficient neural network," *Proc. NIPS*, 2015.
[2] U. Evci, T. Gale, J. Menick, P. S. Castro, and E. Elsen, "Rigging the lottery: Making all tickets winners," *Proc. ICML*, 2020.
[3]
[4]
[5]
[6]
[7]
[8]
[9]
[10]
[11]
[12]