

# 基于 Stage 扫描机制的 Vision RWKV 让医学影像分割轻量而高效

sora\*, Zhendong Li\*

\*Ningxia University

Email: kyochilian@gmail.com, lizhendong@nxu.edu.cn

**Abstract**—基于 Transformer 的分割框架是当前医学影像分割的主流方法,能够构建全局关系。然而,在需要高精度与高分辨率的医学图像分割中,Transformer 计算复杂度高,应用有限。最近的 RWKV 模型降低了空间聚合复杂度并具备全局处理能力,但其在视觉领域存在长程建模羸弱的问题,贪吃蛇效应突出,同时循环嵌套机制在分割领域中的解码性能不足。为了解决这些问题,我们提出了一种基于 Vision RWKV 的分割框架 RWKV-SSS,该框架在具有较低复杂度的同时具备了全局建模能力。为了增强 RWKV 的长程空间连续性,我们设计了一种 Stage 扫描机制,该机制将图像分为全局 block 与局部 block,根据不同 Stage 的编码器,相应调整扫描比例,将全局与局部特征融合,大大提升了模型的精度。同时,我们在解码器中构建了上采样模块---,该模块改良了 RWKV 的循环嵌套机制,提升了重建多尺度特征的能力。我们还采用多种方法进一步降低 SSS 的计算复杂度,实现模型的轻量化。(LRFormer 低分辨率自注意力,池化 QKV 等等)实验表明,我们的方法在多个数据集取得优异性能,同时计算复杂度与计算速度显著增强,使其在高精度分割的同时具备轻量化特性。代码开源至: <https://github.com/shepherdxu/SCI-winning>。

**Index Terms**—computer vision, semantic segmentation, RWKV, Transformer, lightweight

## I. INTRODUCTION

Semantic Segmentation 是计算机视觉中的一项重要任务,医学影像分割是关键应用之一。它将复杂的医学图像分割成不同的区域,使器官、病灶及注意区域清晰可见,对于医学辅助诊断与治疗具有重要意义。相较于人工,使用计算机视觉技术进行辅助诊断不仅提高了诊断效率,还提升了诊断精度,因此许多方法被提出用于医学影像分割任务。多年来,传统的 ML (机器学习) 方法在研究中被广泛应用,如基于图割 (Graph Cut) 的方法 [4]、随机森林 (Random Forest) [5]、支持向量机 (Support Vector Machine, SVM) [6] 以及条件随机场 (Conditional Random Field, CRF) [7] 等。这些方法依赖人工设计的特征提取器,在处理复杂医学图像时存在局限性,由于图像存在模糊、噪声、对比度低等问题,传统方法的准确性和鲁棒性受到限制。

近年来,随着 FCN(Full Convolution Network) [9]、CNN(Convolution Natural Network) [8] 的提出,深度学习方法逐渐代替了传统机器学习方法,语义分割方法的网络深度、特征提取均有了较大提高。随着 Unet [10] 的提出,基于深度学习的分割方法占据了主导地位,通过创新性的 U 型架构,使其成为了语义分割的主流框架,涌现了 Unet++ [?]、Attention-Unet [?] 等方法。2017 年,Google 提出的 Transformer [11] 在自然语言处理 (NLP) 领域 have made 深远影响,which 为视觉领域带来了 ViT(Vision Transformer) [12] in 2020,使得计算机视觉领域拥有了全局注意力 (Global Attention) 与自注意力机

制 (Self-Attention) [11], makes better for 全局语义信息提取,改善了 CNN 的不足 [?]\*\* 等人提出了 TransUnet [?], 将 Unet 与 CNN 和 Transformer 结合起来,使得医学图像分割方法的精度大大提高。

目前,主流的方法主要遵循 TransUnet 的思路,在上述深度学习方法中作修改 [?], 将 CNN 作为局部注意力提取 [?], 为了进行更高精度的分辨,将 Transformer 作为把握全局特征的模块,采用类似 Unet 的上下采样与 skip connection 的结构,达到期望的分割效果 [?]. 然而,医学图像具有低对比度、高分辨率、目标边界模糊等诸多问题 [?], 对于自注意力机制来说缺乏友好,往往需要花费大量的参数来提取低对比度医学特征,牺牲了时间与空间性能 [?], 同时自注意力机制具有平方复杂度,高分辨率的医学图像会使计算复杂度大大增加,高参数网络也不适宜部署在医院等边缘设备,这些限制了 Transformer 在医学图像上的直接应用 [?] [?].

一些研究人员研究改善这种情况。\*\*\*\* 等人提出了 Linear Transformer [?], \*\* 等人在 20xx 年提出了 Mamba [?] 模型,不同于 Transformer 的框架,他们均通过将自注意力机制的复杂度改为线性,从而缓解计算复杂度问题。然而,事实证明,线性复杂度的 Transformer 变体总会牺牲分割精度与准确率,而 Mamba 模型的长序列建模 (SSM) 也不适用于视觉问题 [?]. 鉴于医学影像中 3D 体数据、MRI 与 CT 等高分辨率数据普遍存在,且存在高精度的像素级分割要求,实践中还需要考虑医院边缘设备的部署问题,如何平衡精度与效率、参数与性能,成为急需解决的问题。

Recurrent Weighted Key-Value(RWKV) [?] 的出现引起了我们的关注。其在 NLP 领域的线性复杂度注意力机制,不同于 Transformer 的结构,使其有价值迁移到视觉任务上。Vision RWKV(VRWKV) [?] 尝试了该问题,并针对图像输入进行了结构改进,展现出优异的计算效率与模型精度,\*\* 等人提出了 BSBP-RWKV [?], 首次将 RWKV 应用于医学图像任务,一些研究如 RWKV-Unet [?] 将 VRWKV 与 Unet 迁移到医学图像分割任务上。在高分辨率的医学图像任务下, RWKV 优于其他 Transformer 变体与 Mamba 模型,处理医学图像输入时的推理速度更高,且效果更好 [?].

作为一款线性注意力模型,尽管 RWKV 拥有良好的计算效率与精度,但迁移到图像任务上,还是有不可避免的问题。RWKV 本质是沿序列建模的状态空间式结构,针对离散数据 (如自然语言处理) 的处理过程是固定的,自注意力的处理方式也是一维的。面对连续且二维的图像,基于 RWKV 的图像处理方法是图像分块,并延展为一维,导致了空间连续性上的破坏 [?].

在注意力提取过程中, RWKV 使用一维的方式在二维

图像上进行特征提取,我们称其为贪吃蛇效应<sup>??</sup>。RWKV 的扫描方式是固定的,在图像任务中,注意力的权重往往动态且多变,固定的扫描方式往往会将注意力分片<sup>[?]</sup>。(如图<sup>??</sup>)。若提取到更深层次,图像的特征更容易模糊,RWKV 容易将模糊的特征边缘分离,进行分片扫描,导致容易导致器官边缘、细小病灶(如微小息肉、早期病变区)分割不精细,而这是医学图像分割的要求之一(如图<sup>??</sup>)。同时,医学方向涉及三维数据,在三维医学图像中,边界分割、注意力分片的现象将会更为突出,这为 RWKV 向医学领域的适配带来了挑战<sup>[?]</sup>。

为此,很多工作进行了改进。U-RWKV 提出了方向自适应 RWKV 模块<sup>[?]</sup>,改进了 RWKV 的扫描方式,使其不仅仅局限于一维层面的注意力叠加。Zig-RiR<sup>[?]</sup>提出了 ZigZag 的扫描方案,试图解决 RWKV 扫描的空间连续性问题。然而,其带来了诸多问题:扫描缺乏对图像的动态调整,导致其训练过程不稳定,且不同器官之间的精度存在较大差异<sup>??</sup>;同时,贪吃蛇效应仍然存在;两者工作的上采样过于简单,导致恢复特征分辨率时的精度不足,无法满足医学图像像素级分割的要求。

我们的研究致力于解决该问题。受到 Vision RWKV<sup>[?]</sup>以及 URWKV<sup>[?]</sup>的启发,我们提出了一种基于 RWKV 的 U 型架构 Stage Scan Segmentation,该架构具备完备的编码器-解码器,在保持了 RWKV 的长程依赖和线性复杂度的同时,增强了局部细节的表达与分割的精度。具体来说,我们采用了 Bi-WKV,一种线性注意力,作为我们的注意力核心<sup>[?]</sup>,并提出了 stage scan,一种基于 encoder 层次的扫描机制,根据不同层次的编码器,调整扫描方向与比例。为了解决 RWKV 的空间连续性问题,SSS 将一个维度的模块设置为全局 block 与局部 block,分别提取全局与局部特征。在一开始,输入特征的分辨率与 H、W 较大,特征比较分散,噪声较多,需要我们进行更多的分块扫描。随着编码器的 Stage 增加,输入特征的细节将会更多更集中,图像的分块数也会随着层数的增加而减少<sup>??</sup>,以此把握全局的注意力。在一个模块的前端,我们使用全局 block,较大的 Stage 分块,进行初步的特征提取。随后,采用残差机制<sup>[?]</sup>将提取后的全局权重与原特征相加。局部 block 接收相加后的权重,将 stage 分块进一步增大,进行局部的特征提取。同时,为了缓解贪吃蛇效应<sup>??</sup>,我们改进了四项 token 位移<sup>[?]</sup>,根据已确定的扫描机制,动态调整扫描位移的方向。低参数量<sup>??</sup>。其次,我们对 RWKV 的 WKV 进行适当池化<sup>[?]</sup>,实现进一步的轻量化。最后,我们在上采样阶段实现动态上采样<sup>[?]</sup>,而不仅仅进行反卷积,进一步保留了分割结果的精度与细节。通过这种方式,SSS 获得优于其他方法的特征捕捉能力<sup>??</sup>,增强了对边缘的分割能力和鲁棒性,并发挥了 RWKV 应有的计算效率与低参数量。

总的来说,我们的贡献有:

1. 使用 VRWKV 作为分割的核心方法,达到了线性复杂度与注意力精度的平衡;
2. 提出了基于 Stage 的 Scan 方法,缓解了贪吃蛇效应,有效提取全局特征与局部特征;
3. 在对多个 2d 以及 3d 数据集中,SSS 的效果优于目前许多最先进的方法,同时参数量降低了 20%,GPU 占用降低了 23%<sup>??</sup>。

待写:上采样问题轻量化问题所谓的动态?

加入 RWKV 扫描后的热力图,表示注意力在图像上的衰减

## II. RELATED WORKS

### A. 医学图像分割

目前,基于深度学习的医学图像分割网络是主流,且很多的先进方法均基于 CNN 和 Transformer 的变体得来。

1. 纯净的 CNN。最具代表性的为 Unet<sup>[10]</sup>。UNet 的优势在于编码器-解码器的结构,并通过跳跃连接有效减少信息在传输过程中的损失,实现对复杂医学图像中细微结构的精准分割。部分研究者对 Unet 进行了改进,例如 UNet++、UNet3+、3D UNET 和 Attention Unet 等等。但是,卷积核的有限感受野难以捕捉远程关系和远程关系,限制了模型的分割性能。同时,在面对大尺寸医学图像或三维图像时,UNet 的性能往往不足,导致细节的丢失和全局能力的不足。

2. 纯净的 Transformer。Transformer 的核心机制 self-attention 使其能够把握全局上下文关系,该机制被大量应用至计算机视觉领域,例如 ViT。Transformer 克服了 CNN 在处理长程依赖关系时的不足,并将每个图像块作为输入序列传递到 Transformer 编码器,以获得图像的全局表示。Liu<sup>[?]</sup>等人设计了 SwinTransformer 架构,该架构针对图像分割和目标检测任务设计,并在医学影像分割上取得了不错的成绩。Cao<sup>[?]</sup>等人将 Unet 与 Transformer 架构融合,设计了 Swin-Unet,提升了医学影像的分割精度和泛化能力。Lin<sup>[?]</sup>等人进行了进一步的改进,采用双尺度编码器子网来提取不同语义尺度的特征,建立不同尺度之间的依赖关系。采用纯净 Transformer 的模型对医学图像的精度和鲁棒性较好,但其复杂度较高,精细局部特征提取能力不足,限制了其在医学图像中的应用。

3. 将 CNN 与 Transformer 结合,利用 CNN 在捕捉局部特征上的优越性以及 Transformer 对全局依赖性的处理能力。具有代表性的是 TransUNet<sup>[?]</sup>、CoTr<sup>[?]</sup>、UTNet<sup>[?]</sup>和 Transfuse<sup>[?]</sup>网络等。这些网络通过各种串行、并行的方式将 CNN 与 Transformer 结合到一起,整合了全局与局部特征,使精度进一步提高。该方法的核心问题是:模型计算复杂度较高。Transformer 模块处理图像任务需要将图像序列化,形成较长的序列。尽管 ViT 提出了图像块序列,但图像切割后计算量仍然较大;混合模型需要同时维护 UNet 的卷积层和高复杂度的自注意力机制,虽然增强了细节的特征提取能力,但模型的参数和推理速度均显著降低,无法部署在医院的大量边缘及低算力设备中,应用有限。

改进<sup>[?]</sup>。

### B. 线性注意力

线性注意力致力于打破二次方级的注意力复杂度瓶颈,使注意力机制更加高效,并催生出了一系列 Transformer 变体和非 Transformer 架构。

1. Transformer 变体。一些针对于 Transformer 的改进如 Linear Transformer<sup>[?]</sup>,提出了特征映射的概念,用以替代 Softmax,将 Attention 机制视为 Linear RNN 的过程。<sup>\*\*</sup>等人提出了 Performer<sup>[?]</sup>,引入了正交随机特征(Orthogonal Random Features, ORF),使其接近 Softmax 的效果。二者均通过对 softmax 函数效果的改进,进而达到线性注意力的目的。以此为基础,Han<sup>[?]</sup>等人提

出了 Flatten Transformer, 设计了一种聚焦线性注意力 (Focused Linear Attention), 改善了空间特征的完整性, 完善了线性注意力在视觉领域的应用。

2. *the new wave*. 如经典的 mamba [?] 模型, 其引入了选择性扫描机制 (Selective Scan), 让模型能够根据输入内容动态压缩记忆。U-Mamba [?], Swin-UMamba [?], VM-UNet [?] 等方法探索了 Mamba 模型在医学图像分割领域的运用, 将 Mamba 模型与 SSM 的思想整合进了分割领域当中, 并进行了针对性的优化。然而, SSM 的核心机制致使其无法有效建模初窗口之外的全局上下文信息, 基于 SSM 的视觉模型与最先进的卷积模型和基于注意力的模型相比, 表现不佳, 导致其并不适合视觉任务 [?], 且其运行速度往往以准确率为代价。

### C. RWKV

最近提出的 Receptance Weighted Key Value(RWKV) [?] 是不同于 Transformer 的线性架构, 擅长处理长序列关系与自回归任务, 在 NLP 领域效果优良, 并催生在视觉领域的一系列运用 [?] [?]. 同时, 一些研究人员, 也探索了 RWKV 在医学分割领域的运用 [?] [?] [?].

以此为契机, 我们继续完善专精于医学分割的 RWKV。经过研究, 我们发现, RWKV 不适宜直接运用到分割任务中, 因为原始的因果感受野的机制, 在图像任务中表现不好, 同时, 各种针对图像分割的改进, 没有缓解贪吃蛇效应??, 这导致边界分割模糊, 没有达到像素级分割的要求??, 全局注意力的上下文关系也比较割裂。为了解决该问题, 我们提出了 Stage scan structure, 一种基于 Stage 的 RWKV 扫描方法, 并将一次处理分为全局 block 和局部 block, 以此, 针对特征信息的大小, 进行精准的提取, 保留了空间连续性。同时, 我们改进了 Q-shift, 四向位移机制, 使其动态调整位移方向, 有效缓解贪吃蛇效应。额外地, 在原有的 Bi-WKV 基础上, 我们利用低分辨率的 WKV 实现进一步的轻量化。

## III. METHODS

如图??所示, 我们整体的网络采用了 U 型架构进行设计, 分为下采样、上采样和跳跃连接。其中核心的特征提取在下·采样中。整体而言, 对于一张待分割的二维医学图像, 首先经过 stem, 在网络的初始部分, 以进行早期的特征提取与图像分块。其次, 网络将分块的图像送进 encoder 中, 经过全局 SS 和局部 SS, 不断增加网络深度并提取分割特征。在此期间, 基于 Stage 的扫描机制和 Dynamic Q-shift 将灵活处理分割精度与边界。通过通用的上采样器, 最终输出完整的分割结果。

### A. Stem 与预处理

直接使用原始像素 pixel-level 会导致序列过长, 提高计算度和低频噪声的出现概率 [?], 因此要对输入的图片进行预处理。我们利用卷机的局部归纳偏置, 高效地提取初步特征。图像首先会经过一个 3x3 的卷积块, 经过一个 batch normalization(BN), 随后进入 GeLU 函数进行激活。这个步骤会进行两次。两次 3x3 stride=2 卷积均采用 same padding, 从而保证输出尺寸为  $\frac{H}{4} \times \frac{W}{4}$ 。

在两步卷积过程中, 图像的空间分辨率会快速缩小, 导致在一开始容易丢失边缘细节信息, 不利于高精度的语义分割, 因此, 在初始输入中, 我们引入残差连接 [?] 将输

入图像分枝, 送入分枝的 3x3 卷积中, 与一个 batch norm, 再与原模块进行常规加权, 在深度不变的情况下增强了特征传递。

定义一张输入二维图像为  $X_{in} \in \mathbb{R}^{H \times W \times C_{in}}$ 。对于医学 CT/MRI 图像来说, 通常  $H = W = 256, C_{in} = 1$ 。stem 模块的卷积核大小  $k = 3$ , 步长  $s = 2$ , 经过 stem 模块后, 初始特征图  $F_0 \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4} \times C_0}$ ,  $C_0 = 64$ 。可以看出, 该模块的总下采样率  $S = 4$ , Stage  $i \in \{1, \dots, 4\}$ 。

图像的初步序列化过程被集中到 Stage scan structure 中。

### B. Stage Scan Structure

初步处理后, 我们将特征图分为 global branch 和 local branch, 送入 Stage Scan Structure(SSS) 模块中。SSS 模块由多个 Stage 串联组成, 每个 Stage 包含若干 Bi-WKV 块。

#### 1. Multi-Granularity Windows.

特征图  $F_i$  进入 encoder 后, 我们对其进行分块, 以便于进行特征提取。对于 global branch 与 local branch, 我们采用不同窗口粒度的分块方法。global branch 旨在捕捉长距离依赖, window size 较大, block 数量较少, 序列短; local branch 旨在捕捉局部细节, window size 较小, block 数量较多, 序列长??。这种不同 Granularity 的方法使得模型能够在不同尺度上捕捉图像的全局与局部特征, 提升了分割的精度。

可以看出, 对于 stem 输入的同一张原始图像  $F$ , global branch 的初始窗口分块可以表示为

$$F_0 \xrightarrow{w_g} \{g_1, g_2, \dots, g_{m_g}\} \quad (1)$$

其中  $m_g = \frac{H_0}{w_g} \cdot \frac{W_0}{w_g}$ . 代表分块数量,  $g_i \in \mathbb{R}^{w_g \times w_g \times C_0}$ ,  $w_g$  代表 global branch 的窗口行列。

同样地, local branch 的初始窗口分块可以表示为

$$F_0 \xrightarrow{w_l} \{\ell_1, \ell_2, \dots, \ell_{m_\ell}\} \quad (2)$$

其中  $m_\ell = \frac{H_0}{w_l} \cdot \frac{W_0}{w_l}$ . 代表分块数量,  $\ell_i \in \mathbb{R}^{w_l \times w_l \times C_0}$ ,  $w_l$  代表 local branch 的窗口行列。 $\ell_i \in \mathbb{R}^{w_l \times w_l \times C_i}$ ,  $w_l$  代表 local branch 的窗口行列。

local branch 的窗口大小小于 global branch 的窗口大小, 即  $w_l < w_g$ , 可以表示为

$$w_l = \frac{w_g}{\kappa} \quad (3)$$

其中  $\kappa$  为  $g$  相对于  $l$  的缩放系数。

#### 2. Stage-wise Window Mechanism.

在 SSS 模块中, 我们设计了 Stage-wise Window Mechanism, 根据不同 Stage 的编码器动态地调整 global branch 与 local branch 的窗口比例与分块数量。

我们设计 SWM 的理由是, 随着网络层数加深, 特征图的  $H$  与  $W$  逐渐减小, 分辨率降低, 语义信息增强, 此时需要更多地关注全局上下文信息; 而在浅层语义中, 特征图的  $H$  与  $W$  较大, 分辨率高, 噪声较多, 需要更多地关注局部细节信息。如图??所示, 现有的 RWKV 变体如 Zig RiR [?] 与 URWKV [?] 均采用固定的扫描方式, 没有适应变化的 stage, 导致模型在不同 stage 下的表现不佳, 无法更好地提取特征。

为此，全局与局部分枝的窗口，需要根据 Stage 进行调整。在浅层语义中，特征较为分散，噪声与信息较多，需要更多的分块进行扫描提取特征；在 stage 深层语义中，特征图尺寸随着 stage 的增加逐步变小，语义信息变得越来越丰富，此时更需要模型具备理解全局上下文的能力。

以层数 stage  $i^*$  为变量。设全局窗口边长在所有 stage 上固定为  $w_g = 8$ 。为实现 Stage-wise 自适应，我们采用分段式比例调度  $\kappa(i)$ ，从而令局部窗口  $w_l(i) = w_g/\kappa(i)$  随 stage 变化。公式如下：

$$\kappa(i) = \begin{cases} 4, & i \leq i^*, \\ 2, & i > i^*, \end{cases} \quad w_l(i) = \frac{w_g}{\kappa(i)}. \quad (4)$$

则在第  $i \in \{1, \dots, 4\}$  个 stage 上，全局块和局部块分别将特征图  $F_s$  划分为

$$G_i = \frac{H_i}{w}, w \in \{w_g, w_l\} \quad (5)$$

个非重叠的 blocks，其中  $H_i = W_i$ ，为输入图像的高宽度，序列长度（总块数） $L_i$  即为  $G_i$  的平方。

总而言之，在第  $i$  个 stage 上，Global Branch 可以表示为

$$F_i \xrightarrow{w_g} \{g_{i,1}, \dots, g_{i,L_i^g}\}, \quad L_i^g = \frac{H_i}{w_g} \cdot \frac{W_i}{w_g}. \quad (6)$$

Local Branch 可以表示为

$$F_i \xrightarrow{w_l(i)} \{\ell_{i,1}, \dots, \ell_{i,L_i^l}\}, \quad L_i^l = \frac{H_i}{w_l(i)} \cdot \frac{W_i}{w_l(i)}. \quad (7)$$

明显地， $F$  代表输入的特征图， $L$  代表序列长度，即分块的总数。

### 3. Scan.

许多线性注意力机制，在计算权重时，依赖 token 的一维序列距离  $|t-i|$ ，这使得它们对序列的方向和顺序非常敏感。在一张二维图  $\mathbf{F} \in \mathbb{R}^{H \times W \times C}$ ，当其被序列化为 token 序列时，会产生大量一维序列中相近，但空间二维远离的现象，称之为伪近邻（false neighbors）。注意力机制学习到大量的伪近邻 token，在高权重区域混入不符合二维局部连续性的关系，由此产生只有一维连续性，但没有二维连续性的贪吃蛇效应??。

在不同尺度的特征图上，Bi-WKV [?] 进行特征提取。在 Vision RWKV 中，Bi-WKV 由双向（forward/backward）WKV 组成，用于在序列域聚合上下文。在时间步  $t$  时，生成的双向加权键值聚合结果  $wkv_t$ ，用公式表示为

$$\begin{aligned} wkv_t &= \text{Bi-WKV}(K_s, V_s)_t \\ &= \frac{\sum_{i=0, i \neq t}^{T-1} e^{-(|t-i|-1)/T \cdot w + k_i} v_i + e^{u+k_t} v_t}{\sum_{i=0, i \neq t}^{T-1} e^{-(|t-i|-1)/T \cdot w + k_i} + e^{u+k_t}} \end{aligned} \quad (8)$$

其中， $K_s$  和  $V_s$  分别对应输入序列的键（Key）与值（Value）矩阵； $w$  是位置相关的衰减因子（Decay factor），用于控制空间或时间距离对权重的影响； $u$  代表当前位置的增益系数（Bonus factor）； $T$  为序列的总长度，用于对距离项进行归一化处理。

如式8所示，Bi-WKV 的权重，依赖 token 在一维序列中的相对距离，即为  $|t-i|$ 。对每个 token  $\mathbf{x}_t$ ，其主要有效上下文往往集中在序列邻域

$$\mathcal{N}_R(t) = \{i : |i-t| \leq R\} \quad (9)$$

其中的  $R$  为有效的窗口半径。若  $|t-i|$  小的 token，在二维平面上也相互邻近，则 Bi-WKV 聚合真实的近邻信息；反之，若短序列窗口在二维上跨越较远距离，则会引入大量伪近邻（false neighbors），表现为只有一维连续性而缺乏二维连续性的“贪吃蛇效应”。

传统 raster 扫描会在行尾发生跳跃，破坏空间连续性；ZigZag [?] 扫描方式，虽能缓解一维序列上的跳跃，但最重要的，二维连续性不足，贪吃蛇效应依然存在。为此，我们提出了两种解决方案：**1.Hilbert 扫描**；**2.Dynamic Q-shift**。

不同于之字扫描与蛇形扫描方式，我们使用 Hilbert [?] **空间填充曲线（Hilbert space-filling curve）** 作为扫描顺序。Hilbert 相比上述方式，能更好地保持 2D 空间的邻近关系。这对医学分割很重要，相邻像素通常属于同一语义类别，Hilbert 扫描将 2D 图像序列化为 1D 时，能让语义连续的区域在序列中也保持连续。Hilbert 是一种空间填充曲线，在不同尺度上具有递归结构，在序列化为 token 后，连续的序列片段，在二维上通常是邻接的，减少了伪近邻现象，避免了换行导致的跳跃??。

在 Vision Transformer 及其视觉变体中，使用了 patch embedding + 自注意力机制，token 间并无一维序列关系。但 Bi-WKV 采用序列建模，token 间的相对位置关系对权重计算有重要影响，Hilbert 扫描是具有价值的扫描方式。

在 stage 的 global branch 与 local branch 中，我们采用这种扫描方式。设某  $i$  的 stage 中的特征图  $F_i \in \mathbb{R}^{H_i \times W_i \times C_i}$ ，由公式 4-7，定义一个双射在窗口  $w \times w$  上的 Hilbert 映射为

$$\pi_H^{(i,w)} : \{0, 1, \dots, L_i(w) - 1\} \rightarrow \{0, 1, \dots, G_i(w) - 1\}^2 \quad (10)$$

其中  $\pi_H^{(i,w)}(t) = (r_t, c_t)$  给出序号  $t$  对应的窗口坐标；其逆映射  $(\pi_H^{(i,w)})^{-1}(r, c) = t$  给出每个窗口在序列中的位置。据此，Hilbert 将二维窗口集合  $\{b_{i,r,c}\}$  序列化为

$$\mathbf{X}^{(i,w)} = [\mathbf{x}_0^{(i,w)}, \dots, \mathbf{x}_{L_i(w)-1}^{(i,w)}] \in \mathbb{R}^{L_i(w) \times d} \quad (11)$$

其中

$$\mathbf{x}_t^{(i,w)} = \phi(b_{i, \pi_H^{(i,w)}(t)}), \quad t = 0, \dots, L_i(w) - 1 \quad (12)$$

$\phi(\cdot)$  表示对窗口块的 token 化，输出维度为  $d$ 。

Hilbert 的曲线构造如下：在一个离散网格  $G \times G$  上，定义映射  $G = 2^k$ ：

$$\begin{aligned} \mathcal{H}_k : \{0, 1, \dots, G^2 - 1\} &\rightarrow \{0, 1, \dots, G - 1\}^2, \\ \mathcal{H}_k(t) &= (r_t, c_t) \end{aligned} \quad (13)$$

若  $k = 1$  ( $2 \times 2$ )， $\mathcal{H}_1$  给出基本遍历顺序；当  $k > 1$  时，将网格划分为四个  $(G/2) \times (G/2)$  子象限，对每个象限内使用低阶映射  $\mathcal{H}_{k-1}$  并施加旋转/翻转变换，使得四段子路径首尾相接且整体连续。

离散连续性可以表示为

$$\|\mathcal{H}_k(t+1) - \mathcal{H}_k(t)\|_1 = 1, \quad t = 0, \dots, G^2 - 2. \quad (14)$$

可以看出，对半径  $R$  的序列邻域  $\mathcal{N}_R(t)$ ，其对应的二维序列通常落在紧凑子块中，相邻的序号在二维上保持邻接状

态。在医学分割过程中，使用 Hilbert 扫描，使 Bi-WKV 的有效上下文（由  $|t-i|$  控制）更接近二维局部感受野，也就减少了伪近邻现象。

由图??，Hilbert 扫描，序列的连续片段主要集中在二维左侧区域。对于医学图像而言，病灶、器官往往集中聚合在某一区域，Hilbert 扫描提高了空间邻近的 token 在序列邻域内出现的概率，减少了伪近邻引入的错误聚合，提升了分割精度。实验表明，在医学图像分割任务中，Hilbert 扫描优于传统的扫描方式以及 S 字形扫描 ??。

Hilbert 的定义中，要求窗口网格尺寸  $G_i(w) = H_i/w$  为  $2^k$ 。对于医学图像来说， $H_i$  与  $w$  取值使得  $G_i(w)$  在各 stage 上均为  $2^k$ ，无需额外处理。为了提高鲁棒性，若使用了自定义的数据集，当  $G \neq 2^k$  时，我们为网络添加了处理机制，将网格划分为若干  $2^k \times 2^k$  子块，每个子块内部使用 Hilbert，子块之间，再进行第二次 Hilbert 扫描，to 拼接。

由图??，注意力核心的计算复杂度为

$$O = (2TC). \quad (15)$$

### C. Dynamic Q-shift

虽然改进了 Hilbert 扫描方式，但二维近邻的空间仍是割裂的。贪吃蛇仅仅在序列化时改变了爬行方式，而并没有改善更高维的信息交换。

在 Vision RWKV 中，采用了四向位移机制 (Q-shift) [?]，通过对 token 进行四个方向的位移，增强了空间连续性。Q-shift 的公式如下：

$$Q_{shifted} = \text{ShiftUp}(Q) + \text{ShiftDown}(Q) + \text{ShiftLeft}(Q) + \text{ShiftRight}(Q) \quad (16)$$

这是对网络从一维语义像二维图像的改进，但是，正如上文所说，这种扫描方式，对于序列的方向与顺序较为敏感。同一张 2D 图像，更换一种扫描顺序，相对空间位置会显著变化，从而影响空间连续性。就像贪吃蛇游戏中，蛇头的移动方向决定了蛇身的走向，而无法关系周围的空间结构与顺序。

在本文网络中，为了缓解贪吃蛇效应，我们对 Q-shift 进行了改良，使其动态调整位移方向。

设第  $i$  个 stage 中，在窗口尺度  $w \in \{w_g, w_l(i)\}$  下，块网格尺寸为  $G_i(w) = H_i/w$ ，序列长度为  $L_i(w) = G_i(w)^2$ 。由式 (33) 的 Hilbert 双射  $\pi_H^{(i,w)}(t) = (r_t, c_t)$ ，我们可以为每个序号  $t$  定义其在扫描路径上的“切向”方向 (forward tangent) 为

$$\mathbf{d}_t = \begin{cases} \pi_H^{(i,w)}(t+1) - \pi_H^{(i,w)}(t), & 0 \leq t \leq L_i(w) - 2, \\ \pi_H^{(i,w)}(t) - \pi_H^{(i,w)}(t-1), & t = L_i(w) - 1, \end{cases} \quad (17)$$

由 Hilbert 离散连续性  $\|\pi_H^{(i,w)}(t+1) - \pi_H^{(i,w)}(t)\|_1 = 1$  可知， $\mathbf{d}_t \in \{(\pm 1, 0), (0, \pm 1)\}$ ，即每一步仅在四邻域中移动一格。

接着，令四个单位方向为

$$\mathbf{e}_\uparrow = (-1, 0), \quad \mathbf{e}_\downarrow = (1, 0), \quad \mathbf{e}_\leftarrow = (0, -1), \quad \mathbf{e}_\rightarrow = (0, 1). \quad (18)$$

对于任意方向  $\delta \in \{\uparrow, \downarrow, \leftarrow, \rightarrow\}$ ，定义其与扫描切向是否“共线”（即是否属于扫描路径方向）的指示量

$$a_{t,\delta} = |\mathbf{d}_t^\top \mathbf{e}_\delta| \in \{0, 1\}, \quad (19)$$

其中  $a_{t,\delta} = 1$  表示方向  $\delta$  与扫描切向平行（位于扫描路径上，包含 forward/backward 两向），而  $a_{t,\delta} = 0$  表示方向  $\delta$  与扫描切向正交（位于扫描路径两侧）。

**方向自适应权重。**由于 Bi-WKV 的主要聚合来自序列邻域  $\mathcal{N}_R(t)$  (式 (31))，而  $\mathcal{N}_R(t)$  在二维上天然更偏向扫描切向邻域，因此我们令沿扫描路径方向的位移更弱、非扫描路径（左右侧）方向的位移更强。具体地，构造未归一化权重

$$\tilde{\alpha}_{t,\delta} = \begin{cases} \alpha_\parallel, & a_{t,\delta} = 1, \\ \alpha_\perp, & a_{t,\delta} = 0, \end{cases} \quad \alpha_\perp > \alpha_\parallel, \quad (20)$$

并进行归一化

$$\alpha_{t,\delta} = \frac{\tilde{\alpha}_{t,\delta}}{\sum_{\delta'} \tilde{\alpha}_{t,\delta'}}. \quad (21)$$

将  $\alpha_{t,\delta}$  通过  $(r_t, c_t) = \pi_H^{(i,w)}(t)$  回填到二维网格上，可得权重图  $\alpha_\delta \in \mathbb{R}^{G_i(w) \times G_i(w)}$ ，即

$$\alpha_\delta(r_t, c_t) = \alpha_{t,\delta}. \quad (22)$$

**Dynamic Q-shift。**设当前分枝（窗口尺度  $w$ ）下的 Query 张量为  $Q \in \mathbb{R}^{G_i(w) \times G_i(w) \times d}$ ，则 Dynamic Q-shift 定义为对四向位移结果进行逐位置加权求和：

$$Q_{\text{DQS}} = \alpha_\uparrow \odot \text{ShiftUp}(Q) + \alpha_\downarrow \odot \text{ShiftDown}(Q) + \alpha_\leftarrow \odot \text{ShiftLeft}(Q) + \alpha_\rightarrow \odot \text{ShiftRight}(Q), \quad (23)$$

其中  $\odot$  表示逐位置乘法。

式23 在形式上保持了 Vision RWKV 的四向位移结构，但通过式17–21 使位移方向随扫描路径动态变化。在扫描切向上施加更小的位移权重  $\alpha_\parallel$ ，而对扫描法向施加更大的位移权重  $\alpha_\perp$ ，从机制上增强二维近邻的信息交换，从而进一步缓解贪吃蛇效应并提升边界分割精度。

需要强调的是， $\alpha_\perp, \alpha_\parallel$  不引入额外的注意力计算，仅产生常数级的逐点乘法开销；并且由于其仅由扫描顺序决定，在给定  $i, w$  后可预计算，因此对推理速度影响极小。

### D. Core WKV

在原始的 Vision RWKV 中，RWKV 块分为 Spatial Mix 与 Channel Mix，其中 Spatial Mix 是 RWKV 的注意力的核心，所谓的 Hilbert 扫描也在此改进。

SSS 的 RWKV 块如下图所示??。特征经过 Dynamic Q-Shift 之后，分为 R-S、K-S 和 V-S。

其中，R-S 与 V-S 经过希尔伯特扫描 (Hilbert Scanning) 进入到 WKV 块中，进行核心注意力机制的计算。在计算完毕之后，再次进行一次 WKV 的扫描。

## IV. EXPERIMENTS

实验结果。与 ZigRiR 一致。

TABLE I: Top-1 accuracy (%) on CIFAR-10 under different sparsities.

Method	90% sparsity	95% sparsity
Baseline	93.5	91.2
Magnitude [1]	92.8	89.7
DST (ours)	<b>94.1</b>	<b>92.3</b>

## V. CONCLUSION

We presented a simple yet effective DST framework that dynamically adjusts sparse connectivity during training. Future work includes extending DST to transformer architectures.

## ACKNOWLEDGMENT

This work was supported by the National Natural Science Foundation of China under Grant 62XXXXXX.

## REFERENCES

- [1] S. Han, J. Pool, J. Tran, and W. Dally, “Learning both weights and connections for efficient neural network,” *Proc. NIPS*, 2015.
- [2] U. Evci, T. Gale, J. Menick, P. S. Castro, and E. Elsen, “Rigging the lottery: Making all tickets winners,” *Proc. ICML*, 2020.
- [3]
- [4]
- [5]
- [6]
- [7]
- [8]
- [9]
- [10]
- [11]
- [12]