

基于 Stage 扫描机制的 Vision RWKV 让医学影像分割轻量而高效

sora*, Zhendong Li*

*Ningxia University

Email: kyochilian@gmail.com, lizhendong@nxu.edu.cn

Abstract—基于 Transformer 的分割框架是当前医学影像分割的主流方法，能够构建全局关系。然而，在需要高精度与高分辨率的医学图像分割中，Transformer 计算复杂度高，应用有限。最近的 RWKV 模型降低了空间聚合复杂度并具备全局处理能力，但其在视觉领域存在长程建模羸弱的问题，贪吃蛇效应突出，同时循环嵌套机制在分割领域中的解码性能不足。为了解决这些问题，我们提出了一种基于 Vision RWKV 的分割框架 RWKV-SSS，该框架在具有较低复杂度的同时具备了全局建模能力。为了增强 RWKV 的长程空间连续性，我们设计了一种 Stage 扫描机制，该机制将图像分为全局 block 与局部 block，根据不同 Stage 的编码器，相应调整扫描比例，将全局与局部特征融合，大大提升了模型的精度。同时，我们在解码器中构建了上采样模块---，该模块改良了 RWKV 的循环嵌套机制，提升了重建多尺度特征的能力。我们还采用多种方法进一步降低 SSS 的计算复杂度，实现模型的轻量化。(LRFormer 低分辨率自注意力，池化 QKV 等等) 实验表明，我们的方法在多个数据集取得优异性能，同时计算复杂度与计算速度显著增强，使其在高精度分割的同时具备轻量化特性。代码开源至：<https://github.com/shepherdxu/SCI-winning>。

Index Terms—computer vision, semantic segmentation, RWKV, Transformer, lightweight

I. INTRODUCTION

Semantic Segmentation 是计算机视觉中的一项重要任务，医学影像分割是关键应用之一。它将复杂的医学图像分割成不同的区域，使器官、病灶及注意区域清晰可见，对于医学辅助诊断与治疗具有重要意义。相较于人工，使用计算机视觉技术进行辅助诊断不仅提高了诊断效率，还提升了诊断精度，因此许多方法被提出用于医学影像分割任务。多年来，传统的 ML (机器学习) 方法在研究中被广泛应用，如基于图割 (Graph Cut) 的方法 [4]、随机森林 (Random Forest) [5]、支持向量机 (Support Vector Machine, SVM) [6] 以及条件随机场 (Conditional Random Field, CRF) [7] 等。这些方法依赖人工设计的特征提取器，在处理复杂医学图像时存在局限性，由于图像存在模糊、噪声、对比度低等问题，传统方法的准确性和鲁棒性受到限制。

近年来，随着 FCN(Full Convolution Network) [9]、CNN(Convolution Natural Network) [8] 的提出，深度学习方法逐渐代替了传统机器学习方法，语义分割方法的网络深度、特征提取均有了较大提高。随着 Unet [10] 的提出，基于深度学习的分割方法占据了主导地位，通过创新性的 U 型架构，使其成为了语义分割的主流框架，涌现了 Unet++ [?], Attention-Unet [?] 等方法。2017 年，Google 提出的 Transformer [11] 在自然语言处理 (NLP) 领域 have maked 深远影响，which 为视觉领域带来了 ViT(Vision Transformer) [12] in 2020，使得计算机视觉领域拥有了全局注意力 (Global Attention) 与自注意力机

制 (Self-Attention) [11]，makes better for 全局语义信息提取，改善了 CNN 的不足 [?].** 等人提出了 TransUnet [?], 将 Unet 与 CNN 和 Transformer 结合起来，使得医学图像分割方法的精度大大提高。

目前，主流的方法主要遵循 TransUnet 的思路，在上述深度学习方法中作修改 [?], 将 CNN 作为局部注意力提取 [?], 为了进行更高精度的分辨，将 Transformer 作为把握全局特征的模块，采用类似 Unet 的上下采样与 skip connection 的结构，达到期望的分割效果 [?]. 然而，医学图像具有低对比度、高分辨率、目标边界模糊等诸多问题 [?], 对于自注意力机制来说缺乏友好，往往需要花费大量的参数来提取低对比度医学特征，牺牲了时间与空间性能 [?], 同时自注意力机制具有平方复杂度，高分辨率的医学图像会使计算复杂度大大增加，高参数网络也不适宜部署在医院等边缘设备，这些限制了 Transformer 在医学图像上的直接应用 [?] [?].

一些研究人员研究改善这种情况。**** 等人提出了 Linear Transformer [?], ** 等人在 20xx 年提出了 Mamba [?] 模型，不同于 Transformer 的框架，他们均通过将自注意力机制的复杂度改为线性，从而缓解计算复杂度问题。然而，事实证明，线性复杂度的 Transformer 变体总会牺牲分割精度与准确率，而 Mamba 模型的长序列建模 (SSM) 也不适用于视觉问题 [?]. 鉴于医学影像中 3D 体数据、MRI 与 CT 等高分辨率数据普遍存在，且存在高精度的像素级分割要求，实践中还需要考虑医院边缘设备的部署问题，如何平衡精度与效率、参数与性能，成为急需解决的问题。

Recurrent Weighted Key-Value(RWKV) [?] 的出现引起了我们的关注。其在 NLP 领域的线性复杂度注意力机制，不同于 Transformer 的结构，使其有价值迁移到视觉任务上。Vision RWKV(VRWKV) [?] 尝试了该问题，并针对图像输入进行了结构改进，展现出优异的计算效率与模型精度，** 等人提出了 BSBP-RWKV [?], 首次将 RWKV 应用于医学图像任务，一些研究如 RWKV-Unet [?] 将 VRWKV 与 Unet 迁移到医学图像分割任务上。在高分辨率的医学图像任务下，RWKV 优于其他 Transformer 变体与 Mamba 模型，处理医学图像输入时的推理速度更高，且效果更好 [?].

作为一款线性注意力模型，尽管 RWKV 拥有良好的计算效率与精度，但迁移到图像任务上，还是有不可避免的问题。RWKV 本质是沿序列建模的状态空间式结构，针对离散数据 (如自然语言处理) 的处理过程是固定的，自注意力的处理方式也是一维的。面对连续且二维的图像，基于 RWKV 的图像处理方法是将图像分块，并延展为一维，导致了空间连续性上的破坏 [?].

在注意力提取过程中，RWKV 使用一维的方式在二维

图像上进行特征提取，我们称其为贪吃蛇效应^{??}。RWKV 的扫描方式是固定的，在图像任务中，注意力的权重往往动态且多变，固定的扫描方式往往会将注意力分片^[?]。(如图^{??})。若提取到更深层次，图像的特征更容易模糊，RWKV 容易将模糊的特征边缘分离，进行分片扫描，导致容易导致器官边缘、细小病灶（如微小息肉、早期病变区）分割不精细，而这是医学图像分割的要求之一（如图^{??}）。同时，医学方向涉及三维数据，在三维医学图像中，边界分割、注意力分片的现象将会更为突出，这为 RWKV 向医学领域的适配带来了挑战^[?]。

为此，很多工作进行了改进。U-RWKV 提出了方向自适应 RWKV 模块^[?]，改进了 RWKV 的扫描方式，使其不仅仅局限于一维层面的注意力叠加。Zig-RiR^[?]提出了 ZigZag 的扫描方案，试图解决 RWKV 扫描的空间连续性问题。然而，其带来了诸多问题：扫描缺乏对图像的动态调整，导致其训练过程不稳定，且不同器官之间的精度存在较大差异^{??}；同时，贪吃蛇效应仍然存在；两者工作的上采样过于简单，导致恢复特征分辨率时的精度不足，无法满足医学图像像素级分割的要求。

我们的研究致力于解决该问题。受到 Vision RWKV^[?]以及 URWKV^[?]的启发，我们提出了一种基于 RWKV 的 U 型架构 Stage Scan Segmentation，该架构具备完备的编码器-解码器，在保持了 RWKV 的长程依赖和线性复杂度的同时，增强了局部细节的表达与分割的精度。具体来说，我们采用了 Bi-WKV，一种线性注意力，作为我们的注意力核心^[?]，并提出了 stage scan，一种基于 encoder 层次的扫描机制，根据不同层次的编码器，调整扫描方向与比例。为了解决 RWKV 的空间连续性问题，SSS 将一个维度的模块设置为全局 block 与局部 block，分别提取全局与局部特征。在一开始，输入特征的分辨率与 H、W 较大，特征比较分散，噪声较多，需要我们进行更多的分块扫描。随着编码器的 Stage 增加，输入特征的细节将会更多更集中，图像的分块数也会随着层数的增加而减少^{??}，以此把握全局的注意力。在一个模块的前端，我们使用全局 block，较大的 Stage 分块，进行初步的特征提取。随后，采用残差机制^[?]将提取后的全局权重与原特征加和。局部 block 接收加和后的权重，将 stage 分块进一步增大，进行局部的特征提取。同时，为了缓解贪吃蛇效应^{??}，我们改进了四项 token 位移^[?]，根据已确定的扫描机制，动态调整扫描位移的方向。低参数量^{??}。其次，我们对 RWKV 的 WKV 进行适当池化^[?]，实现进一步的轻量化。最后，我们在上采样阶段实现动态上采样^[?]，而不仅仅进行反卷积，进一步保留了分割结果的精度与细节。通过这种方式，SSS 获得优于其他方法的特征捕捉能力^{??}，增强了对边缘的分割能力和鲁棒性，并发挥了 RWKV 应有的计算效率与低参数量。

总的来说，我们的贡献有：

1. 使用 VRWKV 作为分割的核心方法，达到了线性复杂度与注意力精度的平衡；
2. 提出了基于 Stage 的 Scan 方法，缓解了贪吃蛇效应，有效提取全局特征与局部特征；
3. 在对多个 2d 以及 3d 数据集中，SSS 的效果优于目前许多最先进的方法，同时参数量降低了 20%，GPU 占用降低了 23%^{??}。

待写：上采样问题轻量化问题所谓的动态？

加入 RWKV 扫描后的热力图，表示注意力在图像上的衰减

II. RELATED WORKS

A. 医学图像分割

目前，基于深度学习的医学图像分割网络是主流，且很多的先进方法均基于 CNN 和 Transformer 的变体得来。

1. 纯净的 CNN。最具代表性的为 Unet [10]。UNet 的优势在于编码器-解码器的结构，并通过跳跃连接有效减少信息在传输过程中的损失，实现对复杂医学图像中细微结构的精准分割。部分研究者对 Unet 进行了改进，例如 UNet++、UNet3+、3D UNET 和 Attention Unet 等等。但是，卷积核的有限感受野难以捕捉远程关系和远程关系，限制了模型的分割性能。同时，在面对大尺寸医学图像或三维图像时，UNet 的性能往往不足，导致细节的丢失和全局能力的不足。

2. 纯净的 Transformer。Transformer 的核心机制 self-attention 使其能够把握全局上下文关系，该机制被大量应用至计算机视觉领域，例如 ViT。Transformer 克服了 CNN 在处理长程依赖关系时的不足，并将每个图像块作为输入序列传递到 Transformer 编码器，以获得图像的全局表示。Liu^[?]等人设计了 SwinTransformer 架构，该架构针对图像分割和目标检测任务设计，并在医学影像分割上取得了不错的成绩。Cao^[?]等人将 Unet 与 Transformer 架构融合，设计了 Swin-Unet，提升了医学影像的分割精度和泛化能力。Lin^[?]等人进行了进一步的改进，采用双尺度编码器子网来提取不同语义尺度的特征，建立不同尺度之间的依赖关系。采用纯净 Transformer 的模型对医学图像的精度和鲁棒性较好，但其复杂度较高，精细局部特征提取能力不足，限制了其在医学图像中的应用。

3. 将 CNN 与 Transformer 结合，利用 CNN 在捕捉局部特征上的优越性以及 Transformer 对全局依赖性的处理能力。具有代表性的是 TransUNet^[?]、CoTr^[?]、UTNet^[?]和 Transfuse^[?] 网络等。这些网络通过各种串行、并行的方式将 CNN 与 Transformer 结合到一起，整合了全局与局部特征，使精度进一步提高。该方法的核心问题是：模型计算复杂度较高。Transformer 模块处理图像任务需要将图像序列化，形成较长的序列。尽管 ViT 提出了图像块序列，但图像切割后计算量仍然较大；混合模型需要同时维护 UNet 的卷积层和高复杂度的自注意力机制，虽然增强了细节的特征提取能力，但模型的参数和推理速度均显著降低，无法部署在医院的大量边缘及低算力设备中，应用有限。

改进^[?]。

B. 线性注意力

线性注意力致力于打破二次方级的注意力复杂度瓶颈，使注意力机制更加高效，并催生出了一系列 Transformer 变体和非 Transformer 架构。

1. Transformer 变体。一些针对于 Transformer 的改进如 Linear Transformer^[?]，提出了特征映射的概念，用以替代 Softmax，将 Attention 机制视为 Linear RNN 的过程。^{**} 等人提出了 Performer^[?]，引入了正交随机特征（Orthogonal Random Features, ORF），使其接近 Softmax 的效果。二者均通过对 softmax 函数效果的改进，进而达到线性注意力的目的。以此为基础，Han^[?] 等人提

出了 Flatten Transformer，设计了一种聚焦线性注意力(Focused Linear Attention)，改善了空间特征的完整性，完善了线性注意力在视觉领域的应用。

*2. the new wave。*如经典的 mamba [?] 模型，其引入了选择性扫描机制(Selective Scan)，让模型能够根据输入内容动态压缩记忆。U-Mamba [?]、Swin-UMamba [?]、VM-UNet [?] 等方法探索了 Mamba 模型在医学图像分割领域的运用，将 Mamba 模型与 SSM 的思想整合进了分割领域当中，并进行了针对性的优化。然而，SSM 的核心机制致使其无法有效建模初窗口之外的全局上下文信息，基于 SSM 的视觉模型与最先进的卷积模型和基于注意力的模型相比，表现不佳，导致其并不适合视觉任务 [?]，且其运行速度往往以准确率为代价。

C. RWKV

最近提出的 Receptance Weighted Key Value(RWKV) [?] 是不同于 Transformer 的线性架构，擅长处理长序列关系与自回归任务，在 NLP 领域效果优良，并催生出在视觉领域的一系列运用 [?] [?]. 同时，一些研究人员，也探索了 RWKV 在医学分割领域的运用 [?] [?] [?].

以此为契机，我们继续完善专精于医学分割的 RWKV. 经过研究，我们发现，RWKV 不适宜直接运用至分割任务中，因为原始的因果感受野的机制，在图像任务中表现不好，同时，各种针对图像分割的改进，没有缓解贪吃蛇效应??，这导致边界分割模糊，没有达到像素级分割的要求??，全局注意力的上下文关系也比较割裂。为了解决该问题，我们提出了 Stage scan structure，一种基于 Stage 的 RWKV 扫描方法，并将一次处理分为全局 block 和局部 block，以此，针对特征信息的大小，进行精准的提取，保留了空间连续性。同时，我们改进了 Q-shift，四向位移机制，使其动态调整位移方向，有效缓解贪吃蛇效应。额外地，在原有的 Bi-WKV 基础上，我们利用低分辨率的 WKV 实现进一步的轻量化。

III. METHODS

如图??所示，我们整体的网络采用了 U 型架构进行设计，分为下采样、上采样和跳跃连接。其中核心的特征提取在下采样中。整体而言，对于一张待分割的二维医学图像，首先经过 stem，在网络的初始部分，以进行早期的特征提取与图像分块。其次，网络将分块的图像送进 encoder 中，经过全局 SS 和局部 SS，不断增加网络深度并提取分割特征。在此期间，基于 Stage 的扫描机制和 Dynamic Q-shift 将灵活处理分割精度与边界。通过通用的上采样器，最终输出完整的分割结果。

A. Stem 与预处理

直接使用原始像素 pixel-level 会导致序列过长，提高计算度和低频噪声的出现概率 [?]，因此要对输入的图片进行预处理。我们利用卷机的局部归纳偏置，高效地提取初步特征。图像首先会经过一个 3x3 的卷积块，经过一个 batch normalization(BN)，随后进入 GeLU 函数进行激活。这个步骤会进行两次。两次 3x3 stride=2 卷积均采用 same padding，从而保证输出尺寸为 $\frac{H}{4} \times \frac{W}{4}$ 。

在两步卷积过程中，图像的空间分辨率会快速缩小，导致在一开始容易丢失边缘细节信息，不利于高精度的语义分割，因此，在初始输入中，我们引入残差连接 [?] 将输

入图像分枝，送入分枝的 3x3 卷积中，与一个 batch norm，再与原模块进行常规加权，在深度不变的情况下增强了特征传递。

定义一张输入二维图像为 $X_{in} \in \mathbb{R}^{H \times W \times C_{in}}$ 。对于医学 CT/MRI 图像来说，通常 $H = W = 256, C_{in} = 1$ 。stem 模块的卷积核大小 $k = 3$ ，步长 $s = 2$ ，经过 stem 模块后，初始特征图 $F_0 \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4} \times C_0}, C_0 = 64$ 。可以看出，该模块的总下采样率 $S = 4$ ，Stage i $\in \{1, \dots, 4\}$ 。

图像的初步序列化过程被集中到 Stage scan structure 中。

B. Stage Scan Structure

初步处理后，我们将特征图分为 global branch 和 local branch，送入 Stage Scan Structure(SSS) 模块中。SSS 模块由多个 Stage 串联组成，每个 Stage 包含若干 Bi-WKV 块。

1. Multi-Granularity Windows.

特征图 F_i 进入 encoder 后，我们对其进行分块，以便于进行特征提取。对于 global branch 与 local branch，我们采用不同窗口粒度的分块方法。global branch 旨在捕捉长距离依赖，window size 较大，block 数量较少，序列短；local branch 旨在捕捉局部细节，window size 较小，block 数量较多，序列长??。这种不同 Granularity 的方法使得模型能够在不同尺度上捕捉图像的全局与局部特征，提升了分割的精度。

可以看出，对于 stem 输入的同一张原始图像 F ，global branch 的初始窗口分块可以表示为

$$F_0 \xrightarrow{w_g} \{g_1, g_2, \dots, g_{m_g}\} \quad (1)$$

其中 $m_g = \frac{H_0}{w_g} \cdot \frac{W_0}{w_g}$. 代表分块数量， $g_i \in \mathbb{R}^{w_g \times w_g \times C_0}$ ， w_g 代表 global branch 的窗口行列。

同样地，local branch 的初始窗口分块可以表示为

$$F_0 \xrightarrow{w_l} \{\ell_1, \ell_2, \dots, \ell_{m_\ell}\} \quad (2)$$

其中 $m_\ell = \frac{H_0}{w_l} \cdot \frac{W_0}{w_l}$. 代表分块数量， $\ell_i \in \mathbb{R}^{w_l \times w_l \times C_0}$ ， w_l 代表 local branch 的窗口行列。 $\ell_i \in \mathbb{R}^{w_l \times w_l \times C_i}$ ， w_l 代表 local branch 的窗口行列。

local branch 的窗口大小小于 global branch 的窗口大小，即 $w_l < w_g$ ，可以表示为

$$w_l = \frac{w_g}{\kappa} \quad (3)$$

其中 κ 为 g 相对于 l 的缩放系数。

2. Stage-wise Window Mechanism.

在 SSS 模块中，我们设计了 Stage-wise Window Mechanism，根据不同 Stage 的编码器动态地调整 global branch 与 local branch 的窗口比例与分块数量。

我们设计 SWM 的理由是，随着网络层数加深，特征图的 H 与 W 逐渐减小，分辨率降低，语义信息增强，此时需要更多地关注全局上下文信息；而在浅层语义中，特征图的 H 与 W 较大，分辨率高，噪声较多，需要更多地关注局部细节信息。如图??所示，现有的 RWKV 变体如 Zig RiR [?] 与 URWKV [?] 均采用固定的扫描方式，没有适应变化的 stage，导致模型在不同 stage 下的表现不佳，无法更好地提取特征。

为此，全局与局部分枝的窗口，需要根据 Stage 进行调整。在浅层语义中，特征较为分散，噪声与信息较多，需要更多的分块进行扫描提取特征；在 stage 深层语义中，特征图尺寸随着 stage 的增加逐步变小，语义信息变得越来越丰富，此时更需要模型具备理解全局上下文的能力。

以层数 stage i^* 为变量。设全局窗口边长在所有 stage 上固定为 $w_g = 8$ 。为实现 Stage-wise 自适应，我们采用分段式比例调度 $\kappa(i)$ ，从而令局部窗口 $w_l(i) = w_g/\kappa(i)$ 随 stage 变化。公式如下：

$$\kappa(i) = \begin{cases} 4, & i \leq i^*, \\ 2, & i > i^*, \end{cases} \quad w_l(i) = \frac{w_g}{\kappa(i)}. \quad (4)$$

则在第 $i \in \{1, \dots, 4\}$ 个 stage 上，全局块和局部块分别将特征图 F_s 划分为

$$G_i = \frac{H_i}{w}, w \in \{w_g, w_l\} \quad (5)$$

个非重叠的 blocks，其中 $H_i = W_i$ ，为输入图像的高宽度，序列长度（总块数） L_i 即为 G_i 的平方。

总而言之，在第 i 个 stage 上，Global Branch 可以表示为

$$F_i \xrightarrow{w_g} \{g_{i,1}, \dots, g_{i,L_i^g}\}, \quad L_i^g = \frac{H_i}{w_g} \cdot \frac{W_i}{w_g}. \quad (6)$$

Local Branch 可以表示为

$$F_i \xrightarrow{w_l(i)} \{\ell_{i,1}, \dots, \ell_{i,L_i^\ell}\}, \quad L_i^\ell = \frac{H_i}{w_l(i)} \cdot \frac{W_i}{w_l(i)}. \quad (7)$$

明显地， F 代表输入的特征图， L 代表序列长度，即分块的总数。

3. Scan.

许多线性注意力机制，在计算权重时，依赖 token 的一维序列距离 $|t-i|$ ，这使得它们对序列的方向和顺序非常敏感。在一张二维图 $\mathbf{F} \in \mathbb{R}^{H \times W \times C}$ ，当其被序列化为 token 序列时，会产生大量一维序列中相近，但空间二维远离的现象，称之为伪近邻（false neighbors）。注意力机制学习到大量的伪近邻 token，在高权重区域混入不符合二维局部连续性的关系，由此产生只有一维连续性，但没有二维连续性的贪吃蛇效应??。

在不同尺度的特征图上，Bi-WKV [?] 进行特征提取。在 Vision RWKV 中，Bi-WKV 由双向（forward/backward）WKV 组成，用于在序列域聚合上下文。在时间步 t 时，生成的双向加权键值聚合结果 wkv_t ，用公式表示为

$$wkv_t = \text{Bi-WKV}(K_s, V_s)_t \\ = \frac{\sum_{i=0, i \neq t}^{T-1} e^{-(|t-i|-1)/T \cdot w + k_i} v_i + e^{u+k_t} v_t}{\sum_{i=0, i \neq t}^{T-1} e^{-(|t-i|-1)/T \cdot w + k_i} + e^{u+k_t}} \quad (8)$$

其中， K_s 和 V_s 分别对应输入序列的键（Key）与值（Value）矩阵； w 是位置相关的衰减因子（Decay factor），用于控制空间或时间距离对权重的影响； u 代表当前位置的增益系数（Bonus factor）； T 为序列的总长度，用于对距离项进行归一化处理。

如式8所示，Bi-WKV 的权重，依赖 token 在一维序列中的相对距离，即为 $|t-i|$ 。对每个 token \mathbf{x}_t ，其主要有效上下文往往集中在序列邻域

$$\mathcal{N}_R(t) = \{i : |i-t| \leq R\} \quad (9)$$

其中的 R 为有效的窗口半径。若 $|t-i|$ 小的 token，在二维平面上也相互邻近，则 Bi-WKV 聚合真实的近邻信息；反之，若短序列窗口在二维上跨越较远距离，则会引入大量伪近邻（false neighbors），表现为只有一维连续性而缺乏二维连续性的“贪吃蛇效应”。

传统 raster 扫描会在行尾发生长跳跃，破坏空间连续性；ZigZag [?] 扫描方式，虽能缓解一维序列上的跳跃，但最重要的，二维连续性不足，贪吃蛇效应依然存在。为此，我们提出了两种解决方案：**1.Hilbert 扫描**；**2.Dynamic Q-shift**。

不同于之字扫描与蛇形扫描方式，我们使用 **Hilbert** [?] 空间填充曲线（Hilbert space-filling curve）作为扫描顺序。Hilbert 相比上述方式，能更好地保持 2D 空间的邻近关系。这对医学分割很重要，相邻像素通常属于同一语义类别。Hilbert 扫描将 2D 图像序列化为 1D 时，能让语义连续的区域在序列中也保持连续。Hilbert 是一种空间填充曲线，在不同尺度上具有递归结构，在序列化为 token 后，连续的序列片段，在二维上通常是邻接的，减少了伪近邻现象，避免了换行导致的跳跃??。

在 Vision Transformer 及其视觉变体中，使用了 patch embedding + 自注意力机制，token 间并无一维序列关系。但 Bi-WKV 采用序列建模，token 间的相对位置关系对权重计算有重要影响，Hilbert 扫描是具有价值的扫描方式。

在 stage 的 global branch 与 local branch 中，我们采用这种扫描方式。设某 i 的 stage 中的特征图 $F_i \in \mathbb{R}^{H_i \times W_i \times C_i}$ ，由公式 4-7，定义一个双射在窗口 $w \times w$ 上的 Hilbert 映射为

$$\pi_H^{(i,w)} : \{0, 1, \dots, L_i(w) - 1\} \rightarrow \{0, 1, \dots, G_i(w) - 1\}^2 \quad (10)$$

其中 $\pi_H^{(i,w)}(t) = (r_t, c_t)$ 给出序号 t 对应的窗口坐标；其逆映射 $(\pi_H^{(i,w)})^{-1}(r, c) = t$ 给出每个窗口在序列中的位置。据此，Hilbert 将二维窗口集合 $\{b_{i,r,c}\}$ 序列化为

$$\mathbf{X}^{(i,w)} = [\mathbf{x}_0^{(i,w)}, \dots, \mathbf{x}_{L_i(w)-1}^{(i,w)}] \in \mathbb{R}^{L_i(w) \times d} \quad (11)$$

其中

$$\mathbf{x}_t^{(i,w)} = \phi(b_{i, \pi_H^{(i,w)}(t)}), \quad t = 0, \dots, L_i(w) - 1 \quad (12)$$

$\phi(\cdot)$ 表示对窗口块的 token 化，输出维度为 d 。

Hilbert 的曲线构造如下：在一个离散网格 $G \times G$ 上，定义映射 $G = 2^k$ ：

$$\mathcal{H}_k : \{0, 1, \dots, G^2 - 1\} \rightarrow \{0, 1, \dots, G - 1\}^2, \quad \mathcal{H}_k(t) = (r_t, c_t) \quad (13)$$

若 $k = 1$ (2×2)， \mathcal{H}_1 给出基本遍历顺序；当 $k > 1$ 时，将网格划分为四个 $(G/2) \times (G/2)$ 子象限，对每个象限内使用低阶映射 \mathcal{H}_{k-1} 并施加旋转/翻转变换，使得四段子路径首尾相接且整体连续。

离散连续性可以表示为

$$\|\mathcal{H}_k(t+1) - \mathcal{H}_k(t)\|_1 = 1, \quad t = 0, \dots, G^2 - 2. \quad (14)$$

可以看出，对半径 R 的序列邻域 $\mathcal{N}_R(t)$ ，其对应的二维序列通常落在紧凑子块中，相邻的序号在二维上保持邻接状

态。在医学分割过程中，使用 Hilbert 扫描，使 Bi-WKV 的有效上下文（由 $|t-i|$ 控制）更接近二维局部感受野，也就减少了伪近邻现象。

由图??，Hilbert 扫描，序列的连续片段主要集中在二维左侧区域。对于医学图像而言，病灶、器官往往集中聚合在某一区域，Hilbert 扫描提高了空间邻近的 token 在序列邻域内出现的概率，减少了伪近邻引入的错误聚合，提升了分割精度。实验表明，在医学图像分割任务中，Hilbert 扫描优于传统的扫描方式以及 S 字形扫描 ??。

Hilbert 的定义中，要求窗口网格尺寸 $G_i(w) = H_i/w$ 为 2^k 。对于医学图像来说， H_i 与 w 取值使得 $G_i(w)$ 在各 stage 上均为 2^k ，无需额外处理。为了提高鲁棒性，若使用了自定义的数据集，当 $G \neq 2^k$ 时，我们为网络添加了处理机制，将网格划分为若干 $2^k \times 2^k$ 子块，每个子块内部使用 Hilbert，子块之间，再进行第二次 Hilbert 扫描，to 拼接。

由图??，注意力核心的计算复杂度为

$$O = (2TC). \quad (15)$$

C. Dynamic Q-shift

虽然改进了 Hilbert 扫描方式，但二维近邻的空间仍是割裂的。贪吃蛇仅仅在序列化时改变了爬行方式，而并没有改善更高维的信息交换。

在 Vision RWKV 中，采用了四向位移机制 (Q-shift) [?]，通过对 token 进行四个方向的位移，增强了空间连续性。Q-shift 的公式如下：

$$\begin{aligned} Q_{shifted} = & \text{ShiftUp}(Q) + \text{ShiftDown}(Q) \\ & + \text{ShiftLeft}(Q) + \text{ShiftRight}(Q) \end{aligned} \quad (16)$$

这是对网络从一维语义像二维图像的改进，但是，正如上文所说，这种扫描方式，对于序列的方向与顺序较为敏感。同一张 2D 图像，更换一种扫描顺序，相对空间位置会显著变化，从而影响空间连续性。就像贪吃蛇游戏中，蛇头的移动方向决定了蛇身的走向，而无法关系周围的空间结构与顺序。

在本文网络中，为了缓解贪吃蛇效应，我们对 Q-shift 进行了改良，使其动态调整位移方向。

缓解贪吃蛇效应。Q-shift 对于不在扫描路径上的 token，占比大一些

可以采用对角线扫描

D. Low-Resolution WKV

主要介绍主要的自注意力机制块，和对应的池化，

E. 上采样

IV. EXPERIMENTS

实验结果。与 ZigRiR 一致。

TABLE I: Top-1 accuracy (%) on CIFAR-10 under different sparsities.

Method	90% sparsity	95% sparsity
Baseline	93.5	91.2
Magnitude [1]	92.8	89.7
DST (ours)	94.1	92.3

V. CONCLUSION

We presented a simple yet effective DST framework that dynamically adjusts sparse connectivity during training. Future work includes extending DST to transformer architectures.

ACKNOWLEDGMENT

This work was supported by the National Natural Science Foundation of China under Grant 62XXXXXX.

REFERENCES

- [1] S. Han, J. Pool, J. Tran, and W. Dally, “Learning both weights and connections for efficient neural network,” *Proc. NIPS*, 2015.
- [2] U. Evci, T. Gale, J. Menick, P. S. Castro, and E. Elsen, “Rigging the lottery: Making all tickets winners,” *Proc. ICML*, 2020.
- [3]
- [4]
- [5]
- [6]
- [7]
- [8]
- [9]
- [10]
- [11]
- [12]